



Predicción de la deserción escolar con base en factores institucionales de los estudiantes de la UTM.

Presenta:

Méndez Luis Yakin Senen

Director de tesis:

Dr. Christian Eduardo Millán Hernández

Codirector de tesis:

M.T.C.A Moisés Emmanuel Ramírez Guzmán

Lugar y fecha:

Heroica Ciudad de Huajuapam de León,
Oaxaca
Mayo de 2026

Resumen

La deserción estudiantil en la Universidad Tecnológica de la Mixteca (UTM), especialmente en los primeros semestres, representa un desafío institucional significativo. Ante la carencia de una herramienta para la intervención oportuna, esta investigación tiene como objetivo principal desarrollar un modelo predictivo. Mediante la aplicación de técnicas estadísticas y de aprendizaje automático, este estudio analiza factores institucionales—principalmente el historial de desempeño académico (calificaciones y asistencia)—para identificar patrones de riesgo. El resultado será una herramienta validada capaz de pronosticar la probabilidad de abandono, facilitando así estrategias de retención focalizadas.

Palabras clave:

Deserción escolar, educación superior, modelos predictivos, análisis institucional, aprendizaje automático, Universidad Tecnológica de la Mixteca

Índice

1. Introducción y Planteamiento del Problema	3
1.1. Situación Actual	3
1.2. Problema Central	3
1.3. Objetivo General	3
2. Marco Teórico y Estado del Arte	5
3. Metodología: Adquisición, limpieza e ingeniería de características	6
3.1. Arquitectura del sistema de procesamiento	6
3.2. Extracción y conexión a la base de datos	6
3.3. Saneamiento de datos crudos	6
3.4. Ingeniería de características y estructuración temporal	7
3.4.1. Anonimización criptográfica	7
3.4.2. Construcción de instantáneas (snapshots) y etiquetado	7
3.5. EDA automatizado	8
4. Resultados del EDA	8
4.1. Correlación multivariable y colinealidad	8
4.2. Análisis de correlación Punto-Biserial con la variable Objetivo	9
4.3. Estudio ANOVA (Análisis de varianza)	10
4.4. Estudio de independencia (Chi-Cuadrada) en variables categóricas	12
4.5. Fuerza predictiva por área de conocimiento	13
4.5.1. Análisis crítico de anomalías: Sesgo de supervivencia y ceros estructurales	13
4.6. Umbrales de supervivencia y tolerancia al rezago	14

1. Introducción y Planteamiento del Problema

1.1. Situación Actual

La deserción escolar es un fenómeno persistente en la educación superior en México. La eficiencia terminal en la trayectoria profesional de los estudiantes se ve severamente afectada por el abandono temprano. Si bien los factores económicos tienen un peso importante, el rendimiento académico juega un rol preponderante y directo en la permanencia estudiantil.

A nivel institucional, la Universidad Tecnológica de la Mixteca (UTM) genera y almacena sistemáticamente un volumen considerable de datos transaccionales sobre sus estudiantes. Esta información incluye historiales de calificaciones por parcial, registros de asistencia, materias cursadas y la progresión semestral de cada alumno. Estos datos constituyen un registro objetivo y detallado del desempeño académico.

Actualmente, este repositorio de datos se utiliza principalmente para fines administrativos y de consulta de expedientes. Sin embargo, desde una perspectiva analítica, esta información puede ser analizada para el desarrollo de nuevas estrategias que permitan mejorar los programas de apoyo existentes, como el sistema de tutorías ya que este último opera sin un diagnóstico predictivo que les permita focalizar sus esfuerzos. La asignación de recursos de apoyo se basa en mecanismos reactivos, en lugar de estar informada por un análisis proactivo que identifique de manera automatizada a los estudiantes con mayor riesgo estadístico de abandono.

1.2. Problema Central

Dada la situación actual, el problema central de esta investigación es la carencia de un modelo analítico validado que permita tanto explicar como predecir la deserción estudiantil en la UTM, basándose de manera exclusiva en factores institucionales.

Este problema se desglosa en dos componentes interrelacionados:

1. **La brecha explicativa:** Aunque existe la intuición de que el rendimiento académico influye en la deserción, la institución carece de un modelo explicativo que cuantifique la magnitud de cada factor. Se desconoce qué variables específicas (como el promedio o la constancia en asistencias) son los impulsores más fuertes del abandono.
2. **La brecha predictiva:** Como consecuencia directa, no existe una herramienta de pronóstico proactiva. La incapacidad de identificar a los estudiantes con alta probabilidad de desertar impide que los sistemas de tutoría se focalicen eficientemente.

1.3. Objetivo General

Modelar la relación entre los **factores institucionales** —restringidos exclusivamente a métricas de rendimiento académico tales como calificaciones y asistencias— y la deserción estudiantil en la UTM, para desarrollar un sistema de alerta temprana

que permita focalizar las estrategias de retención basándose en datos internos de la universidad.

2. Marco Teórico y Estado del Arte

Nota: Esta sección mantendrá la base de la revisión literaria definida en el protocolo (conceptos de deserción, aprendizaje automático, modelos de clasificación), la cual será expandida a medida que se integren los resultados de los modelos predictivos y el marco estadístico.

3. Metodología: Adquisición, limpieza e ingeniería de características

Dado el enfoque cuantitativo de esta investigación, la primera fase del proyecto consistió en la cimentación de una arquitectura de datos robusta. Para lograr predecir el riesgo de deserción, fue imperativo extraer, sanear y estructurar los datos transaccionales de la UTM para convertirlos en un conjunto de datos (dataset) apto para algoritmos de aprendizaje automático.

3.1. Arquitectura del sistema de procesamiento

Para garantizar la reproducibilidad y el rigor técnico del procesamiento de datos, se diseñó una arquitectura de software modular utilizando el lenguaje de programación Python (versión 3.13) operando dentro de un entorno virtual aislado.

El sistema fue estructurado en módulos lógicos independientes (`db.connector`, `data_cleaner`, `feature_engineer`, `eda_visualizer`), permitiendo separar las reglas de negocio de la institución de la lógica de conexión y visualización. Para el control de dependencias se utilizaron herramientas de grado industrial como `pandas` para la manipulación matricial, `SQLAlchemy` para la conexión a bases de datos, y `fg-data-profiling` para la automatización del análisis exploratorio de datos (EDA, por sus siglas en inglés).

3.2. Extracción y conexión a la base de datos

La fuente primaria de información corresponde a la base de datos relacional de la UTM, gestionada mediante PostgreSQL. Para salvaguardar la integridad y seguridad de las credenciales de acceso institucional, se implementó un sistema de inyección de variables de entorno mediante un archivo `.env`.

La extracción de los datos históricos de los estudiantes (matriculados entre 2017 y 2025) se realizó construyendo un motor de conexión ORM a través de `SQLAlchemy`. Se ejecutó una consulta estructurada sobre el esquema `kardex_regular`, extrayendo más de 133,000 registros transaccionales que contenían calificaciones parciales (`p1`, `p2`, `p3`), ordinarias (`o`), asistencias (`a1`, `a2`, `a3`) y variables de progresión académica.

3.3. Saneamiento de datos crudos

Los datos extraídos de sistemas transaccionales escolares a menudo contienen marcadores de sistema que no representan valores matemáticos reales. Durante la exploración inicial del conjunto de datos crudos, se detectó que el sistema de gestión escolar registraba el valor numérico de `-10.0` como un comodín para representar evaluaciones o asistencias no capturadas o inválidas.

Introducir este valor en un modelo predictivo habría sesgado drásticamente los cálculos de promedios, varianzas y distribuciones. Por lo tanto, se diseñó un módulo de saneamiento (`data_cleaner`) encargado de iterar sobre todas las métricas académicas y reemplazar el indicador `-10.0` por la estructura nula de Python (`NaN`).

Adicionalmente, se eliminaron los registros huérfanos que carecían de una matrícula válida, garantizando la pureza del conjunto de datos.

3.4. Ingeniería de características y estructuración temporal

La contribución central de esta fase metodológica fue la transformación de registros individuales de materias en perfiles acumulativos que representan el historial de un estudiante a través del tiempo.

3.4.1. Anonimización criptográfica

Para cumplir con los estándares éticos y garantizar la confidencialidad de la población estudiantil, se eliminó la identificación directa de la matrícula. En su lugar, se implementó un algoritmo basado en la función hash criptográfica SHA-256 para combinar la matrícula y el identificador de la carrera (`id_carrera`), generando una nueva variable unívoca denominada `alumno_carrera_hash`. Este identificador permite trazar el comportamiento de un individuo sin revelar su identidad y trata como entidades distintas a un estudiante que cambia de carrera.

3.4.2. Construcción de instantáneas (snapshots) y etiquetado

Debido a que el aprendizaje automático requiere observar el contexto histórico, el comportamiento académico de los estudiantes fue agrupado y ordenado cronológicamente. Se construyeron “instantáneas de progreso” por semestre, acumulando las métricas hasta el corte de evaluación.

Para cada semestre cursado por un estudiante, se calcularon métricas predictivas clave:

- **Promedio acumulado de calificaciones y asistencias:** La media histórica lograda hasta el semestre evaluado.
- **Carga y rezago:** El total de materias cursadas y la sumatoria de materias reprobadas (calificación menor a 6.0).
- **Variabilidad del rendimiento:** La desviación estándar del desempeño académico (`std_calificacion_final`), lo que permite al modelo identificar alumnos con comportamientos erráticos.

Finalmente, se abordó la variable dependiente (Target). Dado que la base de datos no contenía una etiqueta explícita de deserción, se implementó una regla de negocio inferencial: se calculó el semestre máximo alcanzado por cada `alumno_carrera_hash`. Aquellos estudiantes cuyo historial alcanzó el décimo semestre (10) fueron etiquetados con un `resultado_final` de 1 (Graduación/Retención), mientras que aquellos cuyo avance se detuvo en semestres previos fueron etiquetados con 0 (Deserción).

3.5. EDA automatizado

Con el conjunto de datos estructurado y etiquetado, se procedió a la fase descriptiva mediante el uso de **fg-data-profiling**. Esta herramienta procesó la matriz histórica para detectar distribuciones sesgadas, colinealidad entre calificaciones de diferentes parciales y correlaciones fuertes con la etiqueta de deserción.

Para mitigar problemas visuales por la alta densidad de los datos (fenómeno de *overplotting*), se desarrollaron gráficos bivariados agregados. Al reducir los registros a promedios por estudiante, se logró evidenciar una correlación lineal positiva y significativa entre la constancia en la asistencia a las aulas y la calificación final obtenida, diferenciando los patrones de comportamiento entre las distintas carreras de la institución.

4. Resultados del EDA

Previo a la construcción de los modelos de aprendizaje automático, se realizó un EDA exhaustivo sobre las instantáneas (*snapshots*) de progreso semestral. El objetivo de esta fase fue evaluar matemáticamente la calidad, la dispersión y la fuerza predictiva de las características institucionales construidas, respondiendo así a la primera pregunta de investigación planteada en este trabajo.

4.1. Correlación multivariable y colinealidad

Para medir la fuerza y dirección de la relación lineal entre las métricas de rendimiento académico, se calculó la matriz de correlación de Pearson. Este análisis es fundamental para detectar *multicolinealidad*, un fenómeno donde dos o más variables independientes están altamente correlacionadas entre sí, lo cual puede distorsionar los pesos interpretativos de los modelos lineales posteriores (como la regresión logística).




Figura 1: Matriz de correlación de variables institucionales

Como se observa en la figura 1, existe una fuerte correlación positiva entre el promedio_calificacion_final y el resultado_final (0.39), así como con el promedio_asistencia_final (0.50). Por otro lado, variables de penalización como materias_reprobadas muestran una correlación negativa (-0.29) con el éxito del estudiante. También es notable la alta correlación entre materias_cursadas y semestre_actual (0.97), lo cual es lógicamente esperado, pero deberá considerarse para evitar redundancias en el modelado.

4.2. Análisis de correlación Punto-Biserial con la variable Objetivo

Dado que el objetivo central del proyecto es predecir la deserción escolar, se procedió a medir el impacto directo de cada característica institucional frente a la variable objetivo discreta (resultado_final), donde 0 representa “Deserción” y 1 representa “Graduación/Retención”.

Al tratarse de la correlación entre variables continuas (ej. promedio) y una variable binaria, el coeficiente de Pearson calculado actúa estadísticamente como una **Correlación Punto-Biserial**.




Figura 2: Impacto lineal de las variables sobre la retención escolar

La figura 2 ilustra el poder predictivo lineal de cada factor. El `promedio_calificacion_final` y el `semestre_actual` emergen como los factores protectores más fuertes (coeficientes cercanos a 0.4). Por el contrario, el número de `materias_reprobadas` y, de manera muy reveladora, la `std_calificacion_final` (la variabilidad o inestabilidad en las calificaciones) se consolidan como fuertes predictores de riesgo, con coeficientes negativos cercanos a -0.3.

4.3. Estudio ANOVA (Análisis de varianza)

El análisis de correlación de Pearson está estrictamente limitado a medir relaciones lineales. Para superar esta limitación y determinar si el comportamiento académico difiere de manera contundente entre los grupos, se implementó un análisis de varianza (ANOVA de un factor).

Se aplicó el test estadístico F de Fisher para evaluar si la varianza en el `promedio_calificacion_final` y en el `promedio_asistencia_final` es significativamente distinta entre el grupo de alumnos que desertan frente a los que logran terminar la carrera.




Figura 3: Distribución de promedio_calificacion_final por resultado_final (ANOVA)

El estudio ANOVA sobre el **promedio de calificaciones** (Figura 3) arrojó un **Estadístico F de 5220.33** y un **p-value de 0.0000**. Esto indica que la diferencia en las calificaciones obtenidas por los estudiantes que desertan frente a los que se gradúan es estadísticamente significativa y no producto del azar. Como se aprecia visualmente, la mediana de calificaciones de los desertores (0) es marcadamente inferior.




Figura 4: Distribución de promedio_asistencia_final por resultado_final (ANOVA)

De manera análoga, el estudio sobre el **promedio de asistencia** (Figura 4) resultó en un **Estadístico F de 2541.95** y un **p-value de 0.0000**. Esto aporta evidencia irrefutable de que la falta de asistencia a las aulas es un indicador institucional con una influencia real y cuantificable sobre la decisión de abandono del

estudiante en la UTM, mostrando que los estudiantes que logran egresar mantienen, en su gran mayoría, un alto índice de asistencia a lo largo de su trayectoria.

4.4. Estudio de independencia (Chi-Cuadrada) en variables categóricas

Para complementar el análisis de varianza continua y obtener una perspectiva enfocada en el comportamiento estudiantil, se procedió a transformar la variable continua de `promedio_asistencia_final` en una variable categórica ordinal (`categoria_asistencia`). Los estudiantes fueron agrupados en cinco bloques de riesgo institucional: Riesgo (<80 %), Regular (80-84 %), Bueno (85-89 %), Muy Bueno (90-94 %) y Excelente (≥ 95 %).

Para determinar si la proporción de deserción varía significativamente dependiendo del bloque de asistencia al que pertenece el estudiante, se aplicó la prueba estadística Chi-Cuadrada de independencia (χ^2).




Figura 5: Tasa de retención escolar estructurada por bloques de asistencia

La prueba estadística arrojó un **Estadístico χ^2 de 2755.74** con 4 grados de libertad y un **p-value de 0.0000**. Este resultado rechaza contundentemente la hipótesis nula de independencia, demostrando que la categoría de asistencia altera dramáticamente el resultado final del estudiante.

Como se evidencia en el gráfico de barras apiladas al 100 % (Figura 5), existe un efecto de "escalera" perfectamente definido. Los estudiantes en la categoría de *Riesgo* (<80 %) presentan una tasa de deserción crítica, dominando visualmente la proporción (barra roja). Conforme el bloque de asistencia mejora, la probabilidad de deserción disminuye drásticamente, llegando al punto donde los estudiantes con asistencia *Excelente* (≥ 95 %) muestran una tasa de retención y éxito casi total (barra

verde). Este comportamiento confirma que el monitoreo de asistencia es un factor institucional altamente accionable para un sistema de alerta temprana.

4.5. Fuerza predictiva por área de conocimiento

Tras categorizar las materias del plan de estudios en áreas semánticas de conocimiento, se evaluó el impacto lineal de cada bloque sobre la probabilidad de graduación mediante la correlación Punto-Biserial.




Figura 6: Fuerza predictiva de las calificaciones por área de conocimiento

Como se ilustra en la Figura 6, los resultados iniciales mostraron una fuerte correlación positiva en las áreas de *Administración y Gestión* y *Humanidades y Comunicación*, superando contraintuitivamente a las áreas de ciencias básicas (*Matemáticas y Estadística* o *Física y Química*), a pesar de tratarse de carreras de corte tecnológico.

4.5.1. Análisis crítico de anomalías: Sesgo de supervivencia y ceros estructurales

Una revisión profunda de estos resultados estadísticos reveló la presencia de dos fenómenos que distorsionan la interpretación lineal directa, los cuales deben ser mitigados en la fase de modelado predictivo:

1. **Ceros estructurales:** Inicialmente, la ausencia de una materia en el historial del alumno se imputó con un valor de 0.0. Sin embargo, en carreras que no incluyen asignaturas como *Administración* en su plan de estudios original, esta imputación generó un "falso cero". El modelo estadístico interpreta erróneamente que los alumnos de dicha carrera cursaron la materia y fracasaron, distorsionando la varianza de esa categoría.

2. **Sesgo de supervivencia:** Las materias de *Administración y Humanidades* suelen estar ubicadas en los semestres intermedios o finales de los planes de estudio. Los estudiantes que enfrentan dificultades académicas severas suelen desertar en los primeros tres semestres, durante el ciclo de ciencias básicas (la etapa de "filtro"). En consecuencia, la alta correlación de las asignaturas tardías no implica que sean factores protectores causales, sino que únicamente los estudiantes que ya "sobrevivieron" al riesgo inicial logran cursarlas.

Para corregir estos sesgos en las etapas posteriores de aprendizaje automático, se sustituirán los ceros imputados por valores nulos (NaN) manejables por algoritmos basados en árboles, y se incorporará el identificador de la carrera como una variable categórica para contextualizar los planes de estudio.

4.6. Umbrales de supervivencia y tolerancia al rezago

Reconociendo que las ciencias básicas actúan como el verdadero filtro académico temprano, se procedió a analizar la distribución de calificaciones específicamente en el área de *Matemáticas y Estadística*.




Figura 7: Distribución de calificaciones en matemáticas: desertores vs graduados

El análisis de densidad (KDE) presentado en la figura 7 evidencia dos campanas claramente separadas. La intersección de ambas curvas señala un umbral crítico de supervivencia: los estudiantes cuyo promedio acumulado en matemáticas cae por debajo del 6.5 ven multiplicada su probabilidad estadística de pertenecer a la población de desertores (área roja).




Figura 8: Tolerancia al rezago: materias reprobadas por área de conocimiento

Finalmente, se evaluó la tolerancia al rezago (Figura 8). El diagrama de cajas demuestra que el margen de error para lograr la graduación es sumamente estrecho. Los alumnos que alcanzan la titulación (cajas verdes) presentan una mediana de cero materias reprobadas en áreas críticas como *Programación* y *Matemáticas*. Por el contrario, los estudiantes que desertan presentan una acumulación acelerada de materias reprobadas, evidenciando que el fracaso repetido en estas áreas desencadena el abandono institucional.