



Predicción de la deserción escolar con base en factores institucionales de los estudiantes de la UTM.

Presenta:

Méndez Luis Yakin Senen

Director de tesis:

Dr. Christian Eduardo Millán Hernández

Codirector de tesis:

M.T.C.A Moisés Emmanuel Ramírez
Guzmán

Lugar y fecha:

Heroica Ciudad de Huajuapam de León,
Oaxaca
Mayo de 2026

Resumen

La deserción estudiantil en la Universidad Tecnológica de la Mixteca (UTM), especialmente en los primeros semestres, representa un desafío institucional significativo. Ante la carencia de una herramienta para la intervención oportuna, esta investigación tiene como objetivo principal desarrollar un modelo predictivo. Mediante la aplicación de técnicas estadísticas y de aprendizaje automático, este estudio analiza factores institucionales—principalmente el historial de desempeño académico (calificaciones y asistencia)—para identificar patrones de riesgo. El resultado será una herramienta validada capaz de pronosticar la probabilidad de abandono, facilitando así estrategias de retención focalizadas.

Palabras clave:

Deserción escolar, educación superior, modelos predictivos, análisis institucional, aprendizaje automático, Universidad Tecnológica de la Mixteca

Índice

1. Introducción y planteamiento del problema	3
1.1. Situación actual	3
1.2. Problema central	3
1.3. Objetivo general	3
1.4. Objetivos específicos	4
1.5. Justificación	4
2. Marco teórico y estado del arte	6
3. Metodología: Adquisición, limpieza e ingeniería de características	7
3.1. Arquitectura del sistema de procesamiento	7
3.2. Extracción y conexión a la base de datos	8
3.3. Análisis estadístico descriptivo del conjunto de datos	9
3.3.1. Dimensionalidad y población estudiantil	9
3.3.2. Naturaleza y tipología de las variables	9
3.3.3. Análisis univariable: Variables temporales y de progresión . . .	9
3.3.4. Análisis univariable: Ubicación curricular y programa educativo	11
3.3.5. Análisis univariable: Identificadores institucionales y poblacio- nales	14
3.3.6. Análisis univariable: Evaluaciones académicas (Calificaciones)	16
3.3.7. Análisis univariable: Métricas de asistencia y cumplimiento reglamentario	19
3.3.8. Análisis univariable: Resultados finales y evaluaciones extra- ordinarias	22
3.3.9. Evaluación de calidad de datos y anomalías	25
3.4. Saneamiento de datos crudos	26
3.5. Ingeniería de características y estructuración temporal	26
3.5.1. Anonimización criptográfica y trazabilidad	26
3.5.2. Categorización semántica y bloques de riesgo	27
3.5.3. Construcción de instantáneas de progreso (Snapshots)	28
3.5.4. Definición de la variable objetivo (Target)	28
4. Análisis Exploratorio de Datos (EDA)	29
4.1. Correlación multivariable y colinealidad	30
4.2. Análisis de correlación Punto-Biserial con la variable Objetivo	31
4.3. Estudio ANOVA (Análisis de varianza)	31
4.4. Estudio de independencia (Chi-Cuadrada) en variables categóricas . .	33
4.5. Fuerza predictiva por área de conocimiento	34
4.5.1. Análisis crítico de anomalías: Sesgo de supervivencia y ceros estructurales	34
4.6. Umbrales de supervivencia y tolerancia al rezago	35

1. Introducción y planteamiento del problema

1.1. Situación actual

La deserción escolar es un fenómeno persistente en la educación superior en México. La eficiencia terminal en la trayectoria profesional de los estudiantes se ve severamente afectada por el abandono temprano. Si bien los factores económicos tienen un peso importante, el rendimiento académico juega un rol preponderante y directo en la permanencia estudiantil.

A nivel institucional, la Universidad Tecnológica de la Mixteca (UTM) genera y almacena sistemáticamente un volumen considerable de datos transaccionales sobre sus estudiantes. Esta información incluye historiales de calificaciones por parcial, registros de asistencia, materias cursadas y la progresión semestral de cada alumno. Estos datos constituyen un registro objetivo y detallado del desempeño académico.

Actualmente, este repositorio de datos se utiliza principalmente para fines administrativos y de consulta de expedientes. Sin embargo, desde una perspectiva analítica, esta información puede ser analizada para el desarrollo de nuevas estrategias que permitan mejorar los programas de apoyo existentes, como el sistema de tutorías ya que este último opera sin un diagnóstico predictivo que les permita focalizar sus esfuerzos. La asignación de recursos de apoyo se basa en mecanismos reactivos, en lugar de estar informada por un análisis proactivo que identifique de manera automatizada a los estudiantes con mayor riesgo estadístico de abandono.

1.2. Problema central

Dada la situación actual, el problema central de esta investigación es la carencia de un modelo analítico validado que permita tanto explicar como predecir la deserción estudiantil en la UTM, basándose de manera exclusiva en factores institucionales.

Este problema se desglosa en dos componentes interrelacionados:

1. **La brecha explicativa:** Aunque existe la intuición de que el rendimiento académico influye en la deserción, la institución carece de un modelo explicativo que cuantifique la magnitud de cada factor. Se desconoce qué variables específicas (como el promedio o la constancia en asistencias) son los impulsores más fuertes del abandono.
2. **La brecha predictiva:** Como consecuencia directa, no existe una herramienta de pronóstico proactiva. La incapacidad de identificar a los estudiantes con alta probabilidad de desertar impide que los sistemas de tutoría se focalicen eficientemente.

1.3. Objetivo general

Modelar la relación entre los **factores institucionales** —restringidos exclusivamente a métricas de rendimiento académico tales como calificaciones y asistencias— y la deserción estudiantil en la UTM, para desarrollar un sistema de alerta temprana

que permita focalizar las estrategias de retención basándose en datos internos de la universidad.

1.4. Objetivos específicos

Para la consecución del objetivo general y bajo la delimitación de utilizar únicamente fuentes de información institucional, se plantean los siguientes objetivos específicos:

1. **(Fase Descriptiva)** Realizar un análisis estadístico descriptivo y exploratorio sobre el conjunto de datos históricos, enfocándose en la distribución y patrones de las **variables institucionales** (tales como promedios, porcentajes de asistencia y estatus de regularidad) para caracterizar su comportamiento en relación con la deserción.
2. **(Fase Explicativa)** Construir modelos explicativos para identificar y cuantificar la influencia específica de los factores institucionales disponibles. El propósito es determinar qué variables internas (ej. calificaciones por asignatura, inasistencias acumuladas) actúan como los determinantes más significativos del abandono escolar.
3. **(Fase Predictiva)** Diseñar, entrenar y validar un modelo predictivo de aprendizaje automático que utilice **únicamente** los registros académicos e institucionales para estimar la probabilidad de deserción, operacionalizando el resultado en un sistema de semáforo (verde, amarillo, rojo) para el apoyo a la toma de decisiones.

1.5. Justificación

La relevancia de esta investigación radica en su potencial para generar un impacto directo y medible en la eficiencia académica y administrativa de la UTM. El proyecto se justifica desde dos perspectivas principales:

- **Justificación institucional y práctica:** El beneficio más directo es la optimización de los recursos institucionales. Al desarrollar un sistema de alerta temprana (semáforo), los programas de apoyo académico, como las tutorías y asesorías, podrán abandonar un esquema reactivo y adoptar un modelo proactivo. Esto permitirá focalizar el esfuerzo humano y económico en los estudiantes que presentan la mayor probabilidad estadística de deserción, maximizando el impacto de dichas intervenciones y mejorando la tasa de retención y eficiencia terminal de la UTM.
- **Justificación metodológica y del conocimiento:** Este trabajo busca generar un conocimiento específico y contextualizado sobre el fenómeno de la deserción dentro de la UTM. A diferencia de los estudios nacionales, que proveen un panorama general, este proyecto identificará los factores de riesgo y patrones de comportamiento únicos de esta población estudiantil, ajustado a la realidad de la institución. Como señalan ([Agrwal, 2015](#)), la aplicación de

técnicas de minería de datos específicas para cada contexto educativo mejora significativamente la precisión de los modelos frente a soluciones genéricas.

Este sistema servirá como un prototipo que demuestra cómo las técnicas de aprendizaje automático pueden ser aplicadas para resolver problemas institucionales concretos, sentando un precedente para futuros proyectos de ciencia de datos en la universidad.

2. Marco teórico y estado del arte

Nota: Esta sección mantendrá la base de la revisión literaria definida en el protocolo (conceptos de deserción, aprendizaje automático, modelos de clasificación), la cual será expandida a medida que se integren los resultados de los modelos predictivos y el marco estadístico.

3. Metodología: Adquisición, limpieza e ingeniería de características

Dado el enfoque cuantitativo de esta investigación, la primera fase del proyecto consistió en la cimentación de una arquitectura de datos robusta. Para lograr predecir el riesgo de deserción, fue imperativo extraer, sanear y estructurar los datos transaccionales de la UTM para convertirlos en un conjunto de datos apto para algoritmos de aprendizaje automático.

3.1. Arquitectura del sistema de procesamiento

Para garantizar la reproducibilidad, escalabilidad y mantenibilidad del procesamiento de datos, se rechazó el uso de un entorno monolítico o el desarrollo exclusivo sobre cuadernos de experimentación. En su lugar, se diseñó e implementó una arquitectura de software modular utilizando el lenguaje de programación Python (versión 3.13) operando dentro de un entorno virtual aislado (`venv`).

El diseño del sistema se fundamenta teóricamente en el paradigma de *Separación de intereses* (SoC, por sus siglas en inglés), un principio de diseño arquitectónico postulado inicialmente por [Dijkstra \(1982\)](#) y refinado por [Parnas \(1972\)](#), el cual establece que un sistema computacional debe descomponerse en elementos funcionales que interactúen mínimamente entre sí. Asimismo, cada componente fue desarrollado bajo el *Principio de responsabilidad única* (SRP, por sus siglas en inglés) descrito por [Martin \(2017\)](#), asegurando que cada módulo de software tenga una única razón para cambiar, aislándose de las reglas de negocio transaccionales de la institución.

El ecosistema computacional fue estructurado en cuatro módulos lógicos independientes dentro del paquete fuente `src/`. La descripción detallada de los módulos, su responsabilidad algorítmica y su fundamento en la ingeniería de software se sintetizan en el Cuadro 1.

Cuadro 1: Estructura modular del sistema de procesamiento y su fundamento de diseño

Módulo lógico	Responsabilidad algorítmica	Justificación arquitectónica
<code>db_connector.py</code>	Gestión del ciclo de vida de la conexión ORM y abstracción de consultas SQL mediante <code>SQLAlchemy</code> .	Aislamiento de la capa de persistencia. Previene el acoplamiento directo con el DBMS (Fowler, 2002).
<code>data_cleaner.py</code>	Detección, filtrado y transformación de banderas administrativas (-10.0) en estructuras nulas numéricas.	Capa de sanitización y pureza de datos. Garantiza la calidad de entrada al flujo (Munson, 2011).
<code>feature_engineer.py</code>	Anonimización criptográfica SHA-256, cálculo de métricas acumulativas y construcción de <i>snapshots</i> temporales.	Capa de lógica de negocio y transformación matemática de variables predictivas (Kuhn and Johnson, 2013).
<code>eda_visualizer.py</code>	Generación encapsulada de pruebas estadísticas (ANOVA, χ^2) así como el renderizado de gráficos de densidad y boxplots.	Desacoplamiento de la interfaz analítica y visual. Mantiene limpias las capas de cálculo (Boswell and Foucher, 2011).

Esta segmentación modular disminuye drásticamente el acoplamiento y facilita la transición de la fase actual de ingeniería de características hacia la fase subsecuente de modelado predictivo, permitiendo modificar los algoritmos de clasificación sin alterar los procesos de extracción o saneamiento previos.

3.2. Extracción y conexión a la base de datos

La fuente primaria de información corresponde a la base de datos relacional de la UTM, gestionada mediante el sistema PostgreSQL. Para salvaguardar la integridad y seguridad de las credenciales de acceso institucional, se adoptaron los principios de configuración de la metodología *Twelve-Factor App* (Wiggins, 2011). Se implementó un sistema de inyección de dependencias a través de variables de entorno (archivo `.env`), aislando por completo la información sensible del código fuente.

La extracción de los datos históricos de los estudiantes (matriculados entre 2017 y 2025) se realizó construyendo un motor de conexión mediante el patrón de diseño *Object-Relational Mapping* (ORM) a través de la biblioteca `SQLAlchemy`. Este enfoque abstrae las particularidades del dialecto SQL subyacente y permite transaccionar la información directamente hacia estructuras matriciales en memoria (Fowler, 2002). Se ejecutó una consulta estructurada sobre el esquema `nes_public`, extrayendo los registros que contenían calificaciones parciales, ordinarias, asistencias y métricas de progresión académica.

3.3. Análisis estadístico descriptivo del conjunto de datos

Una vez establecida la conexión segura con la base de datos institucional y concretada la extracción, se procedió a realizar un análisis estadístico descriptivo sobre el conjunto de datos crudos. Para garantizar la exhaustividad matemática de este proceso, se implementó un perfilado de datos automatizado utilizando la biblioteca `fg-data-profiling` en el entorno de Python.

El objetivo de esta fase fue comprender la dimensionalidad, los tipos de datos, la presencia de valores nulos y las distribuciones de las variables antes de aplicar cualquier regla de negocio o transformación.

3.3.1. Dimensionalidad y población estudiantil

El perfilado inicial reveló que el repositorio transaccional histórico consta de un volumen masivo de **133,882 registros de calificaciones**. Al evaluar la cardinalidad de los identificadores únicos (la variable `alumno_carrera_hash`), se determinó que la población real sobre la que se construirá el estudio asciende a **5,705 estudiantes únicos**. Este tamaño de muestra otorga una validez estadística robusta para el entrenamiento de futuros modelos de aprendizaje automático.

3.3.2. Naturaleza y tipología de las variables

El conjunto de datos extraído se compone de variables multidimensionales que capturan el ciclo de vida académico del estudiante. El reporte estadístico clasificó estas variables en tres categorías principales:

- **Variables de progresión (Discretas/categóricas):** Incluyen el `semestre` (1 al 10), el identificador de la materia (`id_materia`) y la carrera (`id_carrera`). Actúan como las coordenadas temporales y espaciales del rendimiento.
- **Variables de calificación (Continuas - Reales $\mathbb{R}$):** Representadas por las evaluaciones parciales (`p1`, `p2`, `p3`), la evaluación ordinaria (`o`) y el promedio final (`pf`). El dominio teórico de estas variables es de 0.0 a 10.0.
- **Variables de asistencia (Continuas - Porcentuales):** Comprenden los porcentajes de asistencia por parcial (`a1`, `a2`, `a3`, `oa`) y el promedio de asistencia final (`pa`). Su dominio teórico es de 0 a 100.

3.3.3. Análisis univariable: Variables temporales y de progresión

Este primer bloque define el marco cronológico en el que ocurren las transacciones académicas, permitiendo mapear de manera exacta el ciclo de vida del estudiante y la temporalidad de sus calificaciones dentro del sistema institucional.

1. Año académico (`año_academico`) Representa el ciclo escolar macro (por ejemplo, el ciclo 2020-2021). Su naturaleza es categórica y actúa como el agrupador temporal de mayor jerarquía.

Cuadro 2: Métricas de calidad y distribución para `año_academico`

Métrica	Valor
Tipo de dato	Categorica
Valores distintos (Cardinalidad)	8 (< 0,1 %)
Datos faltantes (<i>Missing</i>)	0 (0,0 %)
Memoria ocupada	7.4 MiB

El hecho de que contenga 8 valores distintos confirma que el conjunto de datos abarca un historial longitudinal de múltiples generaciones. Al tener una cobertura perfecta (cero datos faltantes), se garantiza que ninguna calificación quede huérfana fuera de un ciclo oficial.



Figura 1: Distribución de frecuencias por año académico

2. Periodo (periodo) Aunque el motor de base de datos lo registra como un valor numérico real ($\mathbb{R}$), conceptualmente es el identificador cronológico interno y estrictamente ordinal del sistema de la UTM para cada fase de evaluación.

Cuadro 3: Estadística descriptiva de la variable `periodo`

Métrica	Valor	Métrica	Valor
Mínimo	35	Media	47.86
Máximo	61	Desviación Estándar	7.60
Mediana (Q2)	48	Varianza	57.82
Rango Intercuartílico (IQR)	11	Datos faltantes	0 (0,0 %)

Su progresión limpia (sin valores infinitos, negativos o faltantes) es la columna vertebral que permitió a los algoritmos ordenar históricamente los datos para construir las instantáneas de progreso (*snapshots*) sin generar ambigüedades temporales.




Figura 2: Histograma de distribución de la variable periodo

3. Tipo de periodo (tipo_periodo) Esta variable categórica fragmenta el año académico en sus componentes lógicos institucionales (típicamente Semestre A, Semestre B y el curso de Verano). El reporte indicó una cardinalidad de 3 clases distintas con 0 % de datos faltantes. Desempeña un rol predictivo importante, ya que el modelo debe asimilar que la carga académica y las condiciones de aprobación en un curso de verano tienen un peso analítico y pedagógico distinto al de un semestre regular.

4. Es periodo regular (es_periodo_regular) Actúa como una bandera derivada de naturaleza booleana. Sirve para clasificar de manera binaria si el registro pertenece al flujo normal de la universidad o a un periodo extraordinario.

Cuadro 4: Frecuencia de la variable booleana `es_periodo_regular`

Clase	Conteo	Proporción
Verdadero (True)	131,679	$\approx 98,4 \%$
Falso (False)	2,203	$\approx 1,6 \%$

Como se observa en el Cuadro 4, existe una alta tasa de desbalance estadístico (*Imbalance*). Este comportamiento es pedagógicamente correcto, dado que la inmensa mayoría de las transacciones ocurren en periodos regulares. Sin embargo, ese 1.6 % de datos irregulares es altamente valioso para el modelo predictivo; cursar materias fuera del periodo regular es un indicador sintomático de que el estudiante arrastra rezago e intenta nivelar su retícula, consolidándose como un fuerte rasgo de riesgo de abandono institucional.

3.3.4. Análisis univariable: Ubicación curricular y programa educativo

Este conjunto de variables describe el nivel de avance académico del estudiante en su retícula y el programa institucional al que está adscrito. Son características vitales para contextualizar el rendimiento, ya que la exigencia académica no es la misma en un primer semestre que en un octavo semestre, ni es idéntica entre distintas ingenierías.

5. Nombre del periodo (nombre_periodo) Es la representación alfanumérica y legible del ciclo escolar (por ejemplo, “2020-2021 A”). Su naturaleza es categórica y actúa como una etiqueta semántica directa de la variable numérica **periodo**.

Cuadro 5: Métricas de calidad para la variable **nombre_periodo**

Métrica	Valor
Tipo de dato	Categórica
Valores distintos (Cardinalidad)	23 (< 0,1 %)
Datos faltantes (<i>Missing</i>)	0 (0,0 %)
Alerta del perfilado	Alta correlación

El reporte de calidad arroja una alerta de alta correlación, lo cual es estructuralmente lógico y esperado, ya que existe una relación biunívoca perfecta con la variable **periodo**. Tener cero datos faltantes en sus 23 clases confirma la integridad del mapeo realizado durante la fase de ingeniería de características.



Figura 3: Distribución de frecuencias por nombre del periodo

6. Semestre (semestre) Representa el grado académico cursado por el estudiante. Aunque matemáticamente se procesa como un número real ($\mathbb{R}$), su comportamiento es estrictamente ordinal discreto, acotado por la duración normativa de los programas en la UTM (10 semestres).

Cuadro 6: Estadística descriptiva de la variable **semestre**

Métrica	Valor	Métrica	Valor
Mínimo	1	Media	4.60
Máximo	10	Desviación Estándar	2.95
Mediana (Q2)	4	Rango Intercuartílico (IQR)	5
Asimetría (<i>Skewness</i>)	0.37	Datos faltantes	0 (0,0 %)

La media de 4.60 y una mediana de 4 evidencian un sesgo hacia la izquierda (asimetría positiva de 0.37). Esto es un reflejo transaccional directo de la deserción escolar: existe una mayor concentración de registros y estudiantes en los primeros semestres, volumen que va disminuyendo paulatinamente conforme las cohortes avanzan hacia el décimo semestre.




Figura 4: Histograma de distribución poblacional por semestre

7. Tipo de semestre (`tipo_semestre`) Esta variable categórica binaria clasifica el nivel del estudiante en “Par” o “Impar”.

Cuadro 7: Distribución de la variable categórica `tipo_semestre`

Métrica	Valor
Tipo de dato	Categórica (Booleana conceptual)
Valores distintos	2 (Par, Impar)
Datos faltantes (<i>Missing</i>)	0 (0,0 %)

El perfilado levanta una alerta de alta correlación, derivado de su cálculo determinista a partir de la variable `semestre` a través de la operación módulo 2. Su inclusión metodológica busca capturar fenómenos de estacionalidad, permitiendo evaluar si la deserción presenta picos más agudos en los arranques de ciclo escolar (impares) frente a los cierres de ciclo (pares).




Figura 5: Proporción de registros entre semestres pares e impares

8. Identificador de carrera (`id_carrera`) Identificador interno del programa educativo al que pertenece el estudiante (ingeniería o licenciatura). Computacionalmente es un número real, pero analíticamente debe ser tratado como una variable categórica nominal.

Cuadro 8: Estadística descriptiva de la variable nominal `id_carrera`

Métrica	Valor	Métrica	Valor
Mínimo	2	Media	6.59
Máximo	13	Desviación Estándar	3.11
Programas distintos	12	Datos faltantes	0 (0,0 %)

El análisis confirma la presencia de transacciones provenientes de 12 programas educativos distintos (con identificadores del 2 al 13). Entender esta distribución es crítico, ya que las carreras con mayor volumen de alumnos influirán fuertemente en los pesos globales del modelo, justificando la futura necesidad de codificar esta variable mediante técnicas como *One-Hot Encoding* para que el algoritmo respete los planes de estudio de manera independiente.




Figura 6: Distribución transaccional por programa educativo (*id_carrera*)

3.3.5. Análisis univariable: Identificadores institucionales y poblacionales

Este grupo de variables comprende las llaves transaccionales que relacionan el rendimiento académico con entidades físicas e institucionales: el alumno, la materia y el grupo escolar. Aunque a nivel de base de datos varias de estas columnas se almacenan como valores numéricos, su tratamiento estadístico y de ingeniería de características es estrictamente categórico (nominal).

9. Identificador de grupo (*id_grupo*) Representa la asignación específica de un aula o conjunto de estudiantes en un periodo determinado.

Cuadro 9: Estadística descriptiva de la variable *id_grupo*

Métrica	Valor
Tipo de dato	Numérico Real ($\mathbb{R}$) / Conceptual Categórico
Valores distintos (Grupos únicos)	1,495 (1.1 %)
Datos faltantes (<i>Missing</i>)	0 (0.0 %)
Mínimo / Máximo	1,467 / 3,056

La existencia de 1,495 grupos distintos sin valores nulos indica una alta cardinalidad. El perfilado detectó una alta correlación, lo cual es predecible ya que los grupos están lógicamente vinculados a periodos y materias específicas. Esta variable asegura que las calificaciones correspondan a un bloque académico trazable.




Figura 7: Distribución de frecuencias por identificador de grupo

10. Identificador de materia (`id_materia`) Es el código interno que la UTM asigna a cada asignatura dentro de los planes de estudio.

Cuadro 10: Métricas de cardinalidad para la variable `id_materia`

Métrica	Valor
Valores distintos (Materias únicas)	6,666 (5.0 %)
Datos faltantes (<i>Missing</i>)	0 (0.0 %)
Media de identificadores	10,378.18
Alerta del perfilado	Alta correlación

Con 6,666 valores distintos, esta es una de las variables con mayor cardinalidad del conjunto. Como se estableció previamente en la metodología, procesar 6,666 variables independientes generaría una matriz altamente dispersa (*sparse matrix*) que perjudicaría el aprendizaje automático. Esta métrica justifica cuantitativamente el paso de saneamiento e ingeniería de características donde estas materias fueron mapeadas semánticamente en “áreas de conocimiento” (ej. Matemáticas, Programación).




Figura 8: Dispersión y frecuencia del identificador de materia

11. Matrícula estudiantil (`matricula`) Identificador único oficial asignado a cada alumno desde su ingreso a la universidad.

Cuadro 11: Estadística poblacional de la variable `matricula`

Métrica	Valor	Métrica	Valor
Estudiantes únicos	5,383	Asimetría (<i>Skewness</i>)	-110.42
Datos faltantes	0 (0.0 %)	Curtosis	12,576.56
Mínimo	$\approx 2,012 \times 10^8$	Máximo	$\approx 2,024 \times 10^9$

El perfilado arrojó una advertencia de asimetría extrema (*Skewness* de -110.42) y una curtosis masiva. Matemáticamente, esto se debe a que la matrícula no es un valor continuo, sino un folio administrativo que frecuentemente codifica el año de ingreso (ej. 2017..., 2024...). Los 5,383 valores distintos representan el total exacto de individuos físicos (estudiantes) presentes en el repositorio de datos de la investigación.

Value	Count	Frequency (%)
2016170402	79	0.1%
2018310033	74	0.1%
2015030444	73	0.1%
2016170403	72	0.1%
2017310365	69	0.1%
2015030015	67	0.1%
2018140208	66	< 0.1%
2019110526	66	< 0.1%
2016170134	65	< 0.1%
2018140449	65	< 0.1%
Other values (5373)	133 186	99.5%

Figura 9: Distribución poblacional de matrículas

3.3.6. Análisis univariable: Evaluaciones académicas (Calificaciones)

Este subconjunto agrupa las variables continuas que miden el rendimiento cuantitativo del estudiante a lo largo del semestre: los tres exámenes parciales y la evaluación ordinaria. El dominio teórico de una calificación aprobatoria o reprobatoria real se sitúa estrictamente en el intervalo real $[0,0,10,0]$.

Sin embargo, durante el perfilado se detectaron valores fuera de este dominio (como calificaciones de $-8,0$). Al mapear estas anomalías con la arquitectura de software institucional, se corroboró que los valores negativos funcionan como banderas de estado en la base de datos para ser interpretadas por el sistema NES (desarrollado por KadaSoftware), la interfaz gráfica que muestra el desempeño a los estudiantes. Asimismo, la presencia escalonada de valores faltantes obedece a un sesgo de extracción: la base de datos fue capturada mientras un semestre aún se encontraba en curso, por lo que las evaluaciones tardías (primer, segundo y tercer parcial) aún no habían sido registradas por los docentes.

12. Calificación del primer parcial (`p1`) Representa la primera métrica formal de evaluación del estudiante en una asignatura.

Cuadro 12: Estadística descriptiva y de calidad para la variable p1

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	-8.0 / 10.0	Media	6.72
Datos faltantes	2,162 (1.6 %)	Desviación Estándar	2.96
Ceros absolutos	1,763 (1.3 %)	Asimetría (<i>Skewness</i>)	-1.73
Valores negativos	2,573 (1.9 %)	Rango Inter cuartílico	3.4

La distribución presenta una fuerte asimetría negativa (-1.73), lo cual indica que la gran mayoría de las calificaciones se agrupan en el espectro aprobatorio (el tercer cuartil alcanza 8.9), mientras que la cola izquierda se alarga considerablemente debido a los ceros y las banderas negativas del sistema.




Figura 10: Distribución de frecuencias del primer parcial (p1)

13. Calificación del segundo parcial (p2) Representa el punto intermedio de la evaluación semestral.

Cuadro 13: Estadística descriptiva y de calidad para la variable p2

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	-8.0 / 10.0	Media	6.67
Datos faltantes	8,064 (6.0 %)	Desviación Estándar	3.29
Ceros absolutos	1,758 (1.3 %)	Asimetría (<i>Skewness</i>)	-1.83
Valores negativos	4,116 (3.1 %)	Curtosis	4.15

A diferencia del primer parcial, la tasa de datos faltantes salta abruptamente del 1.6 % al 6.0 %. Como se mencionó anteriormente, esto evidencia el corte temporal de la extracción de los datos. Adicionalmente, se observa un incremento en la desviación estándar y en el volumen de banderas negativas (3.1 %), reflejando una mayor polarización en el rendimiento del alumnado a mitad del semestre.




Figura 11: Distribución de frecuencias del segundo parcial (p2)

14. Calificación del tercer parcial (p3) Constituye la última evaluación de la fase regular antes de derivar al estudiante al examen ordinario.

Cuadro 14: Estadística descriptiva y de calidad para la variable p3

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	-8.0 / 10.0	Media	6.55
Datos faltantes	8,068 (6.0 %)	Desviación Estándar	3.69
Ceros absolutos	2,257 (1.7 %)	Asimetría (<i>Skewness</i>)	-1.85
Valores negativos	6,586 (4.9 %)	Varianza	13.66

El análisis descriptivo revela un deterioro académico generalizado en esta etapa: la media de calificación desciende a 6.55, su punto más bajo en comparación con los parciales anteriores. Asimismo, la proporción de valores negativos y ceros absolutos se incrementa significativamente (alcanzando casi un 6.6 % combinado). Este comportamiento es un indicador robusto de deserción consolidada intra-semestral; los alumnos que perciben matemáticamente imposible aprobar la materia tienden a abandonar la evaluación, lo que el sistema registra mediante dichas banderas y ceros.




Figura 12: Distribución de frecuencias del tercer parcial (p3)

15. Calificación del examen ordinario (o) Evaluación ordinaria del curso. En el modelo institucional, esta calificación representa la mitad de la calificación final del alumno en su respectiva materia.

Cuadro 15: Estadística descriptiva y de calidad para la evaluación ordinaria (o)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	-8.0 / 10.0	Media	6.65
Datos faltantes	8,091 (6.0 %)	Desviación Estándar	3.91
Ceros absolutos	3,588 (2.7 %)	Asimetría (<i>Skewness</i>)	-1.96
Valores negativos	7,348 (5.5 %)	Varianza	15.34

La evaluación ordinaria presenta la mayor dispersión estadística del grupo de calificaciones, evidenciada por una varianza de 15.34 y un incremento dramático en la tasa de ceros absolutos (2.7%). Este fenómeno subraya la naturaleza de esta evaluación como un filtro terminal: una fracción sustancial de los estudiantes, al llegar a esta instancia arrastrando deficiencias acumuladas, obtiene resultados nulos o reprueba la asignatura definitivamente, consolidando su estatus de riesgo.




Figura 13: Distribución de frecuencias del examen ordinario (o)

3.3.7. Análisis univariable: Métricas de asistencia y cumplimiento reglamentario

Este conjunto agrupa las variables que cuantifican el porcentaje de asistencia del estudiante en cada periodo de evaluación (primer, segundo, tercer parcial y ordinario). Teóricamente, el dominio de estas variables se encuentra en el intervalo $[0, 100]$.

Es imperativo analizar estas variables bajo el contexto del reglamento académico de la UTM. La institución penaliza severamente el ausentismo: si un estudiante registra menos del 80 % de asistencias en un parcial determinado (ej. $a1 < 80\%$), pierde automáticamente el derecho a la evaluación, y su calificación correspondiente ($p1$) es capturada como cero absoluto (salvo excepciones dictaminadas por el comité de ética). En consecuencia, la asistencia no es únicamente una métrica de disciplina, sino un filtro transaccional condicionante para la aprobación de la asignatura.

16. Asistencia del primer parcial (a1) Mide el porcentaje de asistencia durante la primera fase del curso.

Cuadro 16: Estadística descriptiva de la asistencia al primer parcial (a1)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	0 / 100	Media	96.83
Datos faltantes	2,185 (1.6 %)	Desviación Estándar	9.04
Ceros absolutos	690 (0.5 %)	Asimetría (<i>Skewness</i>)	-7.67
Mediana (Q2)	100	Curtosis	74.90

La variable presenta una curtosis masiva (74.90) y una asimetría negativa extrema (-7.67). Esto significa que la inmensa mayoría de la población estudiantil tiene una asistencia perfecta (100 %) durante el primer parcial. Los ceros absolutos representan apenas el 0.5 %, indicando que el entusiasmo y el cumplimiento normativo son altos al inicio del semestre.




Figura 14: Distribución de frecuencias para la asistencia del primer parcial (a1)

17. Asistencia del segundo parcial (a2) Mide la asistencia en la fase intermedia del periodo escolar.

Cuadro 17: Estadística descriptiva de la asistencia al segundo parcial (a2)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	0 / 100	Media	95.45
Datos faltantes	8,296 (6.2 %)	Desviación Estándar	12.64
Ceros absolutos	1,615 (1.2 %)	Asimetría (<i>Skewness</i>)	-6.09
Mediana (Q2)	100	Curtosis	41.80

En congruencia con el fenómeno observado en la calificación p2, los datos faltantes experimentan un salto hacia el 6.2 %. Simultáneamente, la proporción de ceros absolutos se duplica (1.2 %) y la media general desciende. La dispersión de los datos aumenta, lo que refleja los primeros indicios de ausentismo en la población que comienza a experimentar dificultades académicas.




Figura 15: Distribución de frecuencias para la asistencia del segundo parcial (a2)

18. Asistencia del tercer parcial (a3) Registra el cumplimiento de asistencia en la fase final regular del curso.

Cuadro 18: Estadística descriptiva de la asistencia al tercer parcial (a3)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	0 / 100	Media	94.06
Datos faltantes	8,616 (6.4 %)	Desviación Estándar	16.12
Ceros absolutos	2,839 (2.1 %)	Asimetría (<i>Skewness</i>)	-4.91
Mediana (Q2)	100	Varianza	260.08

El deterioro de la constancia estudiantil se vuelve estadísticamente visible en esta etapa. Los ceros absolutos casi se cuadruplican respecto al primer parcial (llegando al 2.1 %) y la varianza se dispara a 260.08. Este comportamiento corrobora la hipótesis de deserción intra-semestral: los alumnos que han acumulado calificaciones reprobatorias en p1 y p2 tienden a cesar su asistencia a las aulas, sabiendo que matemáticamente no lograrán la aprobación o incurrirán en la regla institucional de pérdida de derecho por inasistencias acumuladas.




Figura 16: Distribución de frecuencias para la asistencia del tercer parcial (a3)

19. Asistencia del examen ordinario (oa) Asistencia registrada durante el periodo de evaluación ordinaria global.

Cuadro 19: Estadística descriptiva de la asistencia al ordinario (oa)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	0 / 100	Media	94.64
Datos faltantes	17,234 (12.9 %)	Desviación Estándar	18.79
Ceros absolutos	3,983 (3.0 %)	Asimetría (<i>Skewness</i>)	-4.51
Mediana (Q2)	100	Curtosis	19.53

Esta variable destaca por poseer la tasa más alta de datos faltantes de todo el conjunto analizado, alcanzando casi un 13 %. Esta anomalía estadística obedece a las particularidades de la evaluación final y de extracción: un gran volumen de estudiantes no registra este valor, ya sea porque la asignatura u organización institucional no exige este pase de lista específico o porque el estudiante ya abandonó formalmente el curso. A su vez, los ceros absolutos alcanzan su pico máximo (3.0 %), reflejando el abandono definitivo de aquellos alumnos que no se presentaron a defender su calificación en la última instancia disponible.




Figura 17: Distribución de frecuencias para la asistencia del ordinario (oa)

3.3.8. Análisis univariable: Resultados finales y evaluaciones extraordinarias

Este conjunto de métricas consolida el rendimiento global del estudiante en la asignatura y evalúa su desempeño en las etapas de rescate académico (exámenes extraordinarios y especiales). Es en estas variables donde se refleja el impacto directo del rezago y donde operan las reglas de expulsión estatutarias de la institución.

20. Promedio final de la materia (pf) Representa la calificación oficial asentada en el historial del alumno. Reglamentariamente, se calcula promediando la media de los tres exámenes parciales con la calificación del examen ordinario al 50 % cada una.

Cuadro 20: Estadística descriptiva y de calidad para el promedio final (pf)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	0.0 / 10.0	Media	6.61
Datos faltantes	2,088 (1.6 %)	Desviación Estándar	2.72
Ceros absolutos	2,670 (2.0 %)	Asimetría (<i>Skewness</i>)	-1.03
Valores negativos	0 (0.0 %)	Rango Inter cuartílico	2.9

Destaca la ausencia total de valores negativos en esta columna. Esto indica que las “banderas de sistema” observadas en los parciales (ej. -8.0) son procesadas y depuradas por el motor de base de datos antes de asentar el promedio final, transformándose habitualmente en ceros absolutos, los cuales representan el 2.0 % de los registros finales. La asimetría negativa (-1.03) confirma que el grueso poblacional que culmina el curso tiende a ubicarse en el espectro aprobatorio.




Figura 18: Distribución de frecuencias del promedio final (pf)

21. Promedio final de asistencias (pa) Cuantifica el cumplimiento consolidado de asistencia del alumno durante todo el periodo escolar.

Cuadro 21: Estadística descriptiva del promedio final de asistencias (pa)

Métrica	Valor	Métrica	Valor
Mínimo / Máximo	0 / 100	Media	91.45
Datos faltantes	2,088 (1.6 %)	Desviación Estándar	19.40
Ceros absolutos	600 (0.4 %)	Asimetría (<i>Skewness</i>)	-3.03

Aunque la asistencia parcial presentaba altas tasas de faltantes y fluctuaciones, el promedio final estabiliza la métrica, mostrando una media global de 91.45 %. Esta variable se consolida metodológicamente como un fuerte predictor global de retención: un **pa** consistente demuestra resiliencia y disciplina, mientras que caídas bruscas en este promedio anteceden inevitablemente a la reprobación.




Figura 19: Distribución de frecuencias para el promedio final de asistencias (pa)

22 y 23. Evaluaciones extraordinarias (e1 y e2) Estas variables capturan las oportunidades de rescate académico cuando el pf es menor a 6.0. El examen extraordinario 1 (e1) es la primera instancia, y de fallar, se procede al extraordinario 2 (e2).

Cuadro 22: Métricas poblacionales para evaluaciones extraordinarias (e1 y e2)

Métrica	Extraordinario 1 (e1)	Extraordinario 2 (e2)
Datos faltantes	115,507 (86.3 %)	123,263 (92.1 %)
Media de calificación	3.28	1.93
Desviación Estándar	4.22	4.94
Ceros y valores negativos (<i>Banderas</i>)	2.6 %	2.3 %

Desde la perspectiva del análisis de datos, estas columnas exhiben un comportamiento clásico de *variables infladas por nulos*. Las tasas de 86.3 % y 92.1 % de datos faltantes no representan un error de extracción, sino el filtro poblacional de la institución: únicamente el $\approx 13\%$ de las transacciones académicas requiere llegar a un primer extraordinario, y menos del 8 % a un segundo. El colapso progresivo de las medias (de 3.28 en e1 a 1.93 en e2) evidencia que la probabilidad de éxito disminuye drásticamente en instancias de rescate profundo.




Figura 20: Distribución de frecuencias para e1 (Izquierda) y e2 (Derecha)

24. Examen especial (esp) Representa la instancia definitiva de evaluación en el marco normativo de la UTM. Se habilita exclusivamente para alumnos recursadores

que, en un segundo intento de cursar la asignatura, vuelven a agotar y reprobar sus instancias ordinarias y extraordinarias.

Cuadro 23: Estadística de la instancia terminal (**esp**)

Métrica	Valor	Métrica	Valor
Datos faltantes	132,583 (99.0 %)	Media	1.62
Registros válidos (Intentos)	≈ 1,300 (1.0 %)	Desviación Estándar	5.52

Esta variable encapsula la mecánica de la expulsión institucional. Con un 99.0 % de datos faltantes, documenta que solo el 1 % de los registros transaccionales llegan a esta fase crítica. Obtener una calificación menor a 6.0 en el **esp** se traduce en la baja definitiva e irrevocable del estudiante. Por ende, la presencia de valores poblacionales en esta variable funciona heurísticamente como un axioma pre-deserción, donde la media tan baja (1.62) subraya la altísima probabilidad estadística de que el estudiante no logre superar este último filtro.




Figura 21: Distribución de la evaluación de última instancia (**esp**)

3.3.9. Evaluación de calidad de datos y anomalías

El reporte de perfilado fue fundamental para detectar anomalías estructurales inherentes a los sistemas de gestión escolar, las cuales representaban un riesgo crítico para el modelado predictivo:

1. **Ausencia de datos:** Se detectó una proporción significativa de valores faltantes distribuidos de manera asimétrica. Por ejemplo, variables de evaluaciones intermedias como **p2** mostraron hasta un 6.0 % de registros nulos. Esto indica que el periodo aun no se registraba en la base de datos, es decir, era en un periodo de evaluación vigente.
2. **Concentración de ceros:** El análisis de distribución (Histogramas de frecuencia) evidenció una fuerte inflación de ceros lógicos en las variables de calificación y asistencia. Una alta concentración en la banda del cero absoluto suele corresponder a estudiantes que, aunque oficialmente matriculados,

dejaron de asistir a la institución antes de las fechas de evaluación, lo que constituye en sí mismo una señal temprana de deserción.

3. **Valores fuera de dominio:** El análisis de valores extremos detectó la existencia de calificaciones con valores negativos (tales como -10.0 o -8.0). Desde una perspectiva pedagógica, una calificación negativa es imposible; sin embargo, desde la perspectiva del sistema transaccional, estos dígitos funcionan como “indicadores o banderas” del sistema (ej. inasistencia por baja temporal o calificación en espera de ser registrada).

La identificación precisa de estas desviaciones estadísticas (asimetría, curtosis y valores negativos estructurales) justificó metodológicamente la necesidad inminente de desarrollar un módulo de saneamiento, garantizando que el ruido administrativo no contamine la señal predictiva del comportamiento estudiantil.

3.4. Saneamiento de datos crudos

El preprocesamiento es una etapa crítica en el descubrimiento de conocimiento, dado que los datos provenientes de sistemas transaccionales tienden a ser ruidosos, inconsistentes o a poseer estructuras diseñadas para la gestión administrativa, no para el análisis matemático (Han et al., 2011).

Durante la fase de perfilado, se detectó que el sistema de gestión escolar registraba valores numéricos negativos (ej; -10.0) como una bandera del sistema para representar evaluaciones o asistencias no capturadas, inválidas, u otros estados del sistema que no guardan relación con el desempeño del estudiante. Introducir estos valores directamente en un modelo predictivo habría sesgado drásticamente los cálculos de medidas de tendencia central y dispersión.

Por lo tanto, se diseñó el módulo `data_cleaner.py`, encargado de iterar sobre el espacio vectorial de las métricas académicas para reemplazar los indicadores negativos por la estructura nula estándar en ciencia de datos (NaN). Adicionalmente, se aplicaron técnicas de filtrado para eliminar registros huérfanos que carecían de una matrícula válida, garantizando la consistencia topológica del conjunto de datos antes de la fase de modelado.

3.5. Ingeniería de características y estructuración temporal

Los algoritmos de aprendizaje automático requieren que la información sea presentada en representaciones que capturen la estructura y dinámica temporal del problema (Zheng and Casari, 2018). La contribución central de esta fase metodológica fue la transformación de registros individuales de materias en perfiles longitudinales acumulativos, representando el historial de un estudiante a través del tiempo.

3.5.1. Anonimización criptográfica y trazabilidad

Para cumplir con los estándares éticos de protección de datos y garantizar la confidencialidad de la población estudiantil, se eliminó la identificación directa de la

matrícula. Se implementó un algoritmo basado en la función hash criptográfica unidireccional *SHA-256* (Secure Hash Algorithm 256-bit), estandarizada por el Instituto Nacional de Estándares y Tecnología ([National Institute of Standards and Technology \(NIST\), 2015](#)). La función procesa la concatenación de la matrícula y el identificador de la carrera para generar una llave primaria subrogada (`alumno_carrera_hash`).

Cuadro 24: Métricas de la variable derivada `alumno_carrera_hash`

Métrica	Valor
Tipo de dato	Texto (Cadena alfanumérica)
Valores distintos (Perfiles)	5,705 (4.3 %)
Datos faltantes (<i>Missing</i>)	0 (0.0 %)
Memoria ocupada	14.4 MiB

Al evaluar estadísticamente esta nueva característica (Cuadro 24), se obtuvieron 5,705 perfiles únicos. Al comparar esta cifra contra las 5,383 matrículas físicas analizadas en los datos crudos, se obtiene una diferencia de 322 registros. Esto confirma matemáticamente la existencia de 322 eventos de movilidad interna, donde un mismo estudiante generó un nuevo historial académico al cambiar a un nuevo programa educativo (`id_carrera`). Este identificador pseudoanónimo trata como entidades distintas a estos casos, protegiendo la integridad predictiva y asegurando que el fracaso en una carrera previa no contamine la evaluación de rendimiento en la carrera actual.

Value	Count	Frequency (%)
4aa5139f0032cad090af6544...	79	0.1%
67e09839a6a1d3098db0360...	73	0.1%
023d810b3d49209b5521fff5...	72	0.1%
5ef3c2eeee1d3b3bad6e3e2...	67	0.1%
b0e71dbcba0d098eb7ac056...	66	< 0.1%
26e0d25827e71ef1f67e58de...	65	< 0.1%
c8138f11eed0f796dd612038...	65	< 0.1%
1c7306a200032c945d3c233...	65	< 0.1%
0e58158cfb10a30957645e7b...	65	< 0.1%
ac2c2417b0daf34bb5fbc935...	65	< 0.1%
Other values (5695)	133200	99.5%

Figura 22: Distribución uniforme de los perfiles encriptados

3.5.2. Categorización semántica y bloques de riesgo

Previo a la acumulación histórica del desempeño, fue necesario transformar variables de alta cardinalidad y variables continuas en representaciones interpretables

que permitieran aislar los factores institucionales de riesgo:

- **Mapeo de áreas de conocimiento:** La variable de materias (`id_materia`) contenía más de 6,600 valores distintos. Para evitar una matriz dispersa que perjudicara el modelado, se desarrolló un módulo de procesamiento basado en expresiones regulares (Regex) aplicado al nombre nominal de la asignatura. Las materias fueron clasificadas en áreas de conocimiento predefinidas (ej. *Matemáticas y Estadística, Programación y Computación, Humanidades*).
- **Discretización de asistencia:** La métrica continua de promedio de asistencia se transformó en una variable categórica ordinal (`categoria_asistencia`), estructurando a los estudiantes en cinco bloques de riesgo: Riesgo ($< 80\%$), Regular ($80\% - 84\%$), Bueno ($85\% - 89\%$), Muy Bueno ($90\% - 94\%$) y Excelente ($\geq 95\%$).

3.5.3. Construcción de instantáneas de progreso (Snapshots)

Dado que el objetivo es predecir la deserción de manera oportuna, el modelo predictivo no puede evaluar el historial de un alumno de primer semestre utilizando métricas que ocurren en el octavo semestre. Esto ocasionaría un error metodológico severo conocido como fuga de información. Para solucionarlo, el comportamiento académico fue ordenado cronológicamente y se construyeron “instantáneas” de progreso (*snapshots*) iterativas por semestre.

Para cada semestre activo cursado por un estudiante, se calcularon métricas predictivas acumulativas observando únicamente la ventana temporal permitida:

- **Métricas de rendimiento acumulado:** Promedio histórico de calificaciones y asistencias logradas hasta el corte de la evaluación del semestre activo.
- **Métricas de rezago:** Conteo total de materias reprobadas (calificación menor a 6.0), proporcionando al modelo un indicador cuantitativo de la sobrecarga académica.
- **Métricas de variabilidad:** Desviación estándar del desempeño académico (`std_calificacion_final`), lo que permite identificar fluctuaciones o comportamientos erráticos que usualmente anteceden al abandono.
- **Características semánticas granulares:** Agrupación dinámica del promedio y del rezago separada por área de conocimiento. Esta granularidad semántica permite al algoritmo discernir la sensibilidad al fracaso dependiendo de la naturaleza específica de la asignatura.

3.5.4. Definición de la variable objetivo (Target)

Finalmente, se abordó la construcción de la variable dependiente o variable predictiva (`resultado_final`). Ante la ausencia de una etiqueta administrativa explícita de deserción en las tablas de progreso, se implementó una regla inferencial algorítmica: se determinó el semestre máximo alcanzado por cada `alumno_carrera_hash`.

Los estudiantes con historiales que culminan o superan el décimo semestre fueron etiquetados con la clase positiva (1: Graduación/Retención), mientras que aquellos con historiales truncados prematuramente fueron etiquetados con la clase negativa (0: Deserción).

Cuadro 25: Distribución de la variable predictiva `resultado_final`

Clase (Estado Institucional)	Tipo de Dato	Porcentaje Poblacional
1 (Graduado / Retención)	Categórica (Booleana)	$\approx 51,0\%$
0 (Deserción)	Categórica (Booleana)	$\approx 49,0\%$

Como se observa en el Cuadro 25 y la Figura 23, la evaluación de la variable objetivo demuestra un balance de clases cuasi-perfecto. Al no presentar desbalance poblacional, el conjunto de datos estructurado brinda las condiciones matemáticas óptimas para el entrenamiento de algoritmos de clasificación de aprendizaje automático, garantizando que los modelos puedan discernir de forma equitativa los patrones institucionales de calificación y asistencia que conducen al éxito o al abandono escolar.




Figura 23: Balance de clases de la variable objetivo predictiva

4. Análisis Exploratorio de Datos (EDA)

Con el conjunto de datos estructurado y etiquetado, se procedió a la fase descriptiva mediante el uso de `fg-data-profiling`. Esta herramienta procesó la matriz histórica para detectar distribuciones sesgadas, colinealidad entre calificaciones de diferentes parciales y correlaciones fuertes con la etiqueta de deserción.

Para mitigar problemas visuales por la alta densidad de los datos (fenómeno de *overplotting*), se desarrollaron gráficos bivariados agregados. Al reducir los registros a promedios por estudiante, se logró evidenciar una correlación lineal positiva y significativa entre la constancia en la asistencia a las aulas y la calificación final obtenida, diferenciando los patrones de comportamiento entre las distintas carreras de la institución.

Previo a la construcción de los modelos de aprendizaje automático, se realizó un EDA exhaustivo sobre las instantáneas (*snapshots*) de progreso semestral. El

objetivo de esta fase fue evaluar matemáticamente la calidad, la dispersión y la fuerza predictiva de las características institucionales construidas, respondiendo así a la primera pregunta de investigación planteada en este trabajo.

4.1. Correlación multivariable y colinealidad

Para medir la fuerza y dirección de la relación lineal entre las métricas de rendimiento académico, se calculó la matriz de correlación de pearson. Este análisis es fundamental para detectar *multicolinealidad*, un fenómeno donde dos o más variables independientes están altamente correlacionadas entre sí, lo cual puede distorsionar los pesos interpretativos de los modelos lineales posteriores (como la regresión logística).




Figura 24: Matriz de correlación de variables institucionales

Como se observa en la Figura 24, existe una fuerte correlación positiva entre el `promedio_calificacion_final` y el `resultado_final` (0.39), así como con el `promedio_asistencia_final` (0.50). Por otro lado, variables de penalización como `materias_reprobadas` muestran una correlación negativa (-0.29) con el éxito del estudiante. También es notable la alta correlación entre `materias_cursadas` y `semestre_actual` (0.97), lo cual es lógicamente esperado, pero deberá considerarse para evitar redundancias en el modelado.

4.2. Análisis de correlación Punto-Biserial con la variable Objetivo

Dado que el objetivo central del proyecto es predecir la deserción escolar, se procedió a medir el impacto directo de cada característica institucional frente a la variable objetivo discreta (`resultado_final`), donde 0 representa “Deserción” y 1 representa “Graduación/Retención”.

Al tratarse de la correlación entre variables continuas (ej. promedio) y una variable binaria, el coeficiente de Pearson calculado actúa estadísticamente como una **Correlación Punto-Biserial**.




Figura 25: Impacto lineal de las variables sobre la retención escolar

La Figura 25 ilustra el poder predictivo lineal de cada factor. El `promedio_calificacion_final` y el `semestre_actual` emergen como los factores protectores más fuertes (coeficientes cercanos a 0.4). Por el contrario, el número de `materias_reprobadas` y, de manera muy reveladora, la `std_calificacion_final` (la variabilidad o inestabilidad en las calificaciones) se consolidan como fuertes predictores de riesgo, con coeficientes negativos cercanos a -0.3.

4.3. Estudio ANOVA (Análisis de varianza)

El análisis de correlación de Pearson está estrictamente limitado a medir relaciones lineales. Para superar esta limitación y determinar si el comportamiento académico difiere de manera contundente entre los grupos, se implementó un análisis de varianza (ANOVA de un factor).

Se aplicó el test estadístico F de Fisher para evaluar si la varianza en el `promedio_calificacion_final` y en el `promedio_asistencia_final` es significativamente distinta entre el grupo de alumnos que desertan frente a los que logran terminar la carrera.




Figura 26: Distribución de promedio_calificacion_final por resultado_final (ANOVA)

El estudio ANOVA sobre el **promedio de calificaciones** (Figura 26) arrojó un **Estadístico F de 5220.33** y un **p-value de 0.0000**. Esto indica que la diferencia en las calificaciones obtenidas por los estudiantes que desertan frente a los que se gradúan es estadísticamente significativa y no producto del azar. Como se aprecia visualmente, la mediana de calificaciones de los desertores (0) es marcadamente inferior.




Figura 27: Distribución de promedio_asistencia_final por resultado_final (ANOVA)

De manera análoga, el estudio sobre el **promedio de asistencia** (Figura 27) resultó en un **Estadístico F de 2541.95** y un **p-value de 0.0000**. Esto aporta evidencia irrefutable de que la falta de asistencia a las aulas es un indicador institucional con una influencia real y cuantificable sobre la decisión de abandono del

estudiante en la UTM, mostrando que los estudiantes que logran egresar mantienen, en su gran mayoría, un alto índice de asistencia a lo largo de su trayectoria.

4.4. Estudio de independencia (Chi-Cuadrada) en variables categóricas

Para complementar el análisis de varianza continua y obtener una perspectiva enfocada en el comportamiento estudiantil, se procedió a transformar la variable continua de `promedio_asistencia_final` en una variable categórica ordinal (`categoria_asistencia`). Los estudiantes fueron agrupados en cinco bloques de riesgo institucional: Riesgo (<80 %), Regular (80-84 %), Bueno (85-89 %), Muy Bueno (90-94 %) y Excelente (≥ 95 %).

Para determinar si la proporción de deserción varía significativamente dependiendo del bloque de asistencia al que pertenece el estudiante, se aplicó la prueba estadística Chi-Cuadrada de independencia (χ^2).




Figura 28: Tasa de retención escolar estructurada por bloques de asistencia

La prueba estadística arrojó un **Estadístico χ^2 de 2755.74** con 4 grados de libertad y un **p-value de 0.0000**. Este resultado rechaza contundentemente la hipótesis nula de independencia, demostrando que la categoría de asistencia altera dramáticamente el resultado final del estudiante.

Como se evidencia en el gráfico de barras apiladas al 100 % (Figura 28), existe un efecto de “escalera” perfectamente definido. Los estudiantes en la categoría de *Riesgo* (<80 %) presentan una tasa de deserción crítica, dominando visualmente la proporción (barra roja). Conforme el bloque de asistencia mejora, la probabilidad de deserción disminuye drásticamente, llegando al punto donde los estudiantes con asistencia *Excelente* (≥ 95 %) muestran una tasa de retención y éxito casi total (barra

verde). Este comportamiento confirma que el monitoreo de asistencia es un factor institucional altamente accionable para un sistema de alerta temprana.

4.5. Fuerza predictiva por área de conocimiento

Tras categorizar las materias del plan de estudios en áreas semánticas de conocimiento, se evaluó el impacto lineal de cada bloque sobre la probabilidad de graduación mediante la correlación Punto-Biserial.




Figura 29: Fuerza predictiva de las calificaciones por área de conocimiento

Como se ilustra en la Figura 29, los resultados iniciales mostraron una fuerte correlación positiva en las áreas de *Administración y Gestión* y *Humanidades y Comunicación*, superando contraintuitivamente a las áreas de ciencias básicas (*Matemáticas y Estadística* o *Física y Química*), a pesar de tratarse de carreras de corte tecnológico.

4.5.1. Análisis crítico de anomalías: Sesgo de supervivencia y ceros estructurales

Una revisión profunda de estos resultados estadísticos reveló la presencia de dos fenómenos que distorsionan la interpretación lineal directa, los cuales deben ser mitigados en la fase de modelado predictivo:

1. **Ceros estructurales:** Inicialmente, la ausencia de una materia en el historial del alumno se imputó con un valor de 0.0. Sin embargo, en carreras que no incluyen asignaturas como *Administración* en su plan de estudios original, esta imputación generó un “falso cero”. El modelo estadístico interpreta erróneamente que los alumnos de dicha carrera cursaron la materia y fracasaron, distorsionando la varianza de esa categoría.

2. **Sesgo de supervivencia:** Las materias de *Administración y Humanidades* suelen estar ubicadas en los semestres intermedios o finales de los planes de estudio. Los estudiantes que enfrentan dificultades académicas severas suelen desertar en los primeros tres semestres, durante el ciclo de ciencias básicas (la etapa de “filtro”). En consecuencia, la alta correlación de las asignaturas tardías no implica que sean factores protectores causales, sino que únicamente los estudiantes que ya “sobrevivieron” al riesgo inicial logran cursarlas.

Para corregir estos sesgos en las etapas posteriores de aprendizaje automático, se sustituirán los ceros imputados por valores nulos (NaN) manejables por algoritmos basados en árboles, y se incorporará el identificador de la carrera como una variable categórica para contextualizar los planes de estudio.

4.6. Umbrales de supervivencia y tolerancia al rezago

Reconociendo que las ciencias básicas actúan como el verdadero filtro académico temprano, se procedió a analizar la distribución de calificaciones específicamente en el área de *Matemáticas y Estadística*.




Figura 30: Distribución de calificaciones en matemáticas: desertores vs graduados

El análisis de densidad (KDE) presentado en la Figura 30 evidencia dos campanas claramente separadas. La intersección de ambas curvas señala un umbral crítico de supervivencia: los estudiantes cuyo promedio acumulado en matemáticas cae por debajo del 6.5 ven multiplicada su probabilidad estadística de pertenecer a la población de desertores (área roja).




Figura 31: Tolerancia al rezago: materias reprobadas por área de conocimiento

Finalmente, se evaluó la tolerancia al rezago (Figura 31). El diagrama de cajas demuestra que el margen de error para lograr la graduación es sumamente estrecho. Los alumnos que alcanzan la titulación (cajas verdes) presentan una mediana de cero materias reprobadas en áreas críticas como *Programación* y *Matemáticas*. Por el contrario, los estudiantes que desertan presentan una acumulación acelerada de materias reprobadas, evidenciando que el fracaso repetido en estas áreas desencadena el abandono institucional.

Referencias

- Agrwal, L & Paik, A. (2015). A survey on data mining techniques for early prediction of student drop out. *International Journal on Computer Science and Engineering*, 7(7):61–70.
- Boswell, D. and Foucher, T. (2011). *The Art of Readable Code*. O'Reilly Media, Inc., Sebastopol, CA.
- Dijkstra, E. W. (1982). *Selected Writings on Computing: A Personal Perspective*. Springer-Verlag, New York.
- Fowler, M. (2002). *Patterns of Enterprise Application Architecture*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA.
- Han, J., Kamber, M., and Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition.
- Kuhn, M. and Johnson, K. (2013). *Applied Predictive Modeling*. Springer, New York.
- Martin, R. C. (2017). *Clean Architecture: A Craftsman's Guide to Software Structure and Design*. Prentice Hall, Boston, MA.

- Munson, T. (2011). *Data Preprocessing in Predictive Data Mining*. John Wiley & Sons, New Jersey.
- National Institute of Standards and Technology (NIST) (2015). Secure hash standard (shs). FIPS PUB 180-4, U.S. Department of Commerce.
- Parnas, D. L. (1972). On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, 15(12):1053–1058.
- Wiggins, A. (2011). *The Twelve-Factor App*. Accedido en mayo de 2026.
- Zheng, A. and Casari, A. (2018). *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. O'Reilly Media, Inc., Sebastopol, CA.