



Predicción de la deserción escolar con base en factores institucionales de los estudiantes de la UTM.

Presenta:

Méndez Luis Yakin Senen

Director de tesis:

Dr. Christian Eduardo Millán Hernández

Codirector de tesis:

M.T.C.A Moisés Emmanuel Ramírez
Guzmán

Lugar y fecha:

Heroica Ciudad de Huajuapam de León,
Oaxaca
Mayo de 2026

Resumen

La deserción estudiantil en la Universidad Tecnológica de la Mixteca (UTM), especialmente en los primeros semestres, representa un desafío institucional significativo. Ante la carencia de una herramienta para la intervención oportuna, esta investigación tiene como objetivo principal desarrollar un modelo predictivo. Mediante la aplicación de técnicas estadísticas y de aprendizaje automático, este estudio analiza factores institucionales—principalmente el historial de desempeño académico (calificaciones y asistencia)—para identificar patrones de riesgo. El resultado será una herramienta validada capaz de pronosticar la probabilidad de abandono, facilitando así estrategias de retención focalizadas.

Palabras clave:

Deserción escolar, educación superior, modelos predictivos, análisis institucional, aprendizaje automático, Universidad Tecnológica de la Mixteca

Índice

1. Introducción y planteamiento del problema	3
1.1. Situación actual	3
1.2. Problema central	3
1.3. Objetivo general	3
1.4. Objetivos específicos	4
1.5. Justificación	4
2. Marco teórico y estado del arte	5
3. Metodología: Adquisición, limpieza e ingeniería de características	6
3.1. Arquitectura del sistema de procesamiento	6
3.2. Extracción y conexión a la base de datos	6
3.3. Reglas de perfilado y saneamiento de datos crudos	7
3.4. Ingeniería de características y estructuración temporal	7
3.4.1. Anonimización criptográfica	7
3.4.2. Categorización semántica	7
3.4.3. Construcción de instantáneas de progreso (Snapshots)	8
3.4.4. Definición algorítmica de la variable objetivo (Target)	8
4. Resultados del análisis exploratorio de datos	9
4.1. Análisis estadístico descriptivo (Perfilado de datos crudos)	9
4.1.1. Variables temporales y de progresión	9
4.1.2. Ubicación curricular y programa educativo	10
4.1.3. Identificadores institucionales y poblacionales	11
4.1.4. Evaluaciones académicas (Calificaciones)	11
4.1.5. Métricas de asistencia y cumplimiento reglamentario	12
4.1.6. Resultados finales y evaluaciones extraordinarias	12
4.2. Resultados de la ingeniería de características	13
4.3. Análisis exploratorio bivariable (EDA)	14
4.3.1. Correlación multivariable lineal	14
4.3.2. Estudio de varianza continua (ANOVA)	15
4.3.3. Independencia categórica de la asistencia (χ^2)	15
5. Discusión de resultados	17
5.1. Fuerza predictiva y sesgos institucionales detectados	17
5.2. Determinación de umbrales críticos y margen de rezago	17
6. Modelado explicativo: Regresión logística y razón de momios	18
6.1. Diagnóstico y eliminación de multicolinealidad (VIF)	19
6.2. Ajuste del modelo y significancia global	19
6.3. Extracción e interpretación de los Odds Ratios (Razón de momios)	19
6.4. Derivación de reglas de decisión institucional	20

1. Introducción y planteamiento del problema

1.1. Situación actual

La deserción escolar es un fenómeno persistente en la educación superior en México. La eficiencia terminal en la trayectoria profesional de los estudiantes se ve severamente afectada por el abandono temprano. Si bien los factores económicos tienen un peso importante, el rendimiento académico juega un rol preponderante y directo en la permanencia estudiantil.

A nivel institucional, la Universidad Tecnológica de la Mixteca (UTM) genera y almacena sistemáticamente un volumen considerable de datos transaccionales sobre sus estudiantes. Esta información incluye historiales de calificaciones por parcial, registros de asistencia, materias cursadas y la progresión semestral de cada alumno. Estos datos constituyen un registro objetivo y detallado del desempeño académico.

Actualmente, este repositorio de datos se utiliza principalmente para fines administrativos y de consulta de expedientes. Sin embargo, desde una perspectiva analítica, esta información puede ser analizada para el desarrollo de nuevas estrategias que permitan mejorar los programas de apoyo existentes, como el sistema de tutorías ya que este último opera sin un diagnóstico predictivo que les permita focalizar sus esfuerzos. La asignación de recursos de apoyo se basa en mecanismos reactivos, en lugar de estar informada por un análisis proactivo que identifique de manera automatizada a los estudiantes con mayor riesgo estadístico de abandono.

1.2. Problema central

Dada la situación actual, el problema central de esta investigación es la carencia de un modelo analítico validado que permita tanto explicar como predecir la deserción estudiantil en la UTM, basándose de manera exclusiva en factores institucionales.

Este problema se desglosa en dos componentes interrelacionados:

1. **La brecha explicativa:** Aunque existe la intuición de que el rendimiento académico influye en la deserción, la institución carece de un modelo explicativo que cuantifique la magnitud de cada factor. Se desconoce qué variables específicas (como el promedio o la constancia en asistencias) son los impulsores más fuertes del abandono.
2. **La brecha predictiva:** Como consecuencia directa, no existe una herramienta de pronóstico proactiva. La incapacidad de identificar a los estudiantes con alta probabilidad de desertar impide que los sistemas de tutoría se focalicen eficientemente.

1.3. Objetivo general

Modelar la relación entre los **factores institucionales** —restringidos exclusivamente a métricas de rendimiento académico tales como calificaciones y asistencias— y la deserción estudiantil en la UTM, para desarrollar un sistema de alerta temprana

que permita focalizar las estrategias de retención basándose en datos internos de la universidad.

1.4. Objetivos específicos

Para la consecución del objetivo general y bajo la delimitación de utilizar únicamente fuentes de información institucional, se plantean los siguientes objetivos específicos:

1. **(Fase Descriptiva)** Realizar un análisis estadístico descriptivo y exploratorio sobre el conjunto de datos históricos, enfocándose en la distribución y patrones de las variables institucionales.
2. **(Fase Explicativa)** Desarrollar modelos explicativos basados en análisis de multicolinealidad (VIF) y regresión logística para cuantificar la razón de momios (*Odds Ratios*) de los factores institucionales, complementados con árboles de decisión para la obtención de reglas de riesgo interpretables.
3. **(Fase Predictiva)** Diseñar, entrenar y validar un modelo predictivo de aprendizaje automático que utilice únicamente los registros académicos e institucionales para estimar la probabilidad de deserción.

1.5. Justificación

La relevancia de esta investigación radica en su potencial para generar un impacto directo y medible en la eficiencia académica y administrativa de la UTM. El proyecto se justifica desde dos perspectivas principales:

- **Justificación institucional y práctica:** El beneficio más directo es la optimización de los recursos institucionales. Al desarrollar un sistema de alerta temprana (semáforo), los programas de apoyo académico, como las tutorías y asesorías, podrán abandonar un esquema reactivo y adoptar un modelo proactivo.
- **Justificación metodológica y del conocimiento:** Este trabajo busca generar un conocimiento específico y contextualizado sobre el fenómeno de la deserción dentro de la UTM identificando los factores de riesgo únicos de esta población estudiantil, ajustado a la realidad de la institución ([Agrwal, 2015](#)).

2. Marco teórico y estado del arte

Nota: Esta sección mantendrá la base de la revisión literaria definida en el protocolo (conceptos de deserción, aprendizaje automático, modelos de clasificación), la cual será expandida a medida que se integren los resultados de los modelos predictivos y el marco estadístico.

3. Metodología: Adquisición, limpieza e ingeniería de características

Dado el enfoque cuantitativo de esta investigación, la primera fase del proyecto consistió en la cimentación de una arquitectura de datos robusta. Para lograr predecir el riesgo de deserción, fue imperativo extraer, sanear y estructurar los datos transaccionales de la UTM para convertirlos en un conjunto de datos apto para algoritmos de aprendizaje automático.

3.1. Arquitectura del sistema de procesamiento

Para garantizar la reproducibilidad, escalabilidad y mantenibilidad del procesamiento de datos, se diseñó e implementó una arquitectura de software modular utilizando el lenguaje de programación Python (versión 3.13) operando dentro de un entorno virtual aislado (`venv`).

El diseño del sistema se fundamenta teóricamente en el paradigma de *Separación de intereses* (SoC), un principio de diseño arquitectónico postulado por [Dijkstra \(1982\)](#) y refinado por [Parnas \(1972\)](#). Asimismo, cada componente fue desarrollado bajo el *Principio de responsabilidad única* (SRP) descrito por [Martin \(2017\)](#).

Cuadro 1: Estructura modular del sistema de procesamiento y su fundamento de diseño

Módulo lógico	Responsabilidad algorítmica	Justificación arquitectónica
<code>db_connector.py</code>	Gestión del ciclo de vida de la conexión ORM y abstracción de consultas SQL.	Aislamiento de la capa de persistencia (Fowler, 2002).
<code>data_cleaner.py</code>	Detección, filtrado y transformación de banderas administrativas.	Capa de sanitización y pureza de datos (Munson, 2011).
<code>feature_engineer.py</code>	Anonimización criptográfica SHA-256 y cálculo de métricas acumulativas.	Capa de lógica de negocio y transformación matemática (Kuhn and Johnson, 2013).
<code>eda_visualizer.py</code>	Generación encapsulada de pruebas estadísticas (ANOVA, χ^2) y gráficos.	Desacoplamiento de la interfaz analítica y visual (Boswell and Foucher, 2011).

3.2. Extracción y conexión a la base de datos

La fuente primaria de información corresponde a la base de datos relacional de la UTM (PostgreSQL). Para salvaguardar la integridad de las credenciales, se adoptaron los principios de configuración de la metodología *Twelve-Factor App* ([Wiggins, 2011](#)).

La extracción de los datos históricos de los estudiantes se realizó construyendo un motor de conexión ORM a través de la biblioteca `SQLAlchemy` ([Fowler, 2002](#)). Se

ejecutó una consulta estructurada sobre el esquema `nes_public`, extrayendo calificaciones, asistencias y métricas de progresión académica.

3.3. Reglas de perfilado y saneamiento de datos crudos

Una vez concretada la extracción, se estableció un protocolo de perfilado utilizando la biblioteca `fg-data-profiling`. El objetivo metodológico fue inspeccionar la dimensionalidad y detectar valores fuera de dominio teórico antes de cualquier transformación.

El preprocesamiento es una etapa crítica, dado que los datos de sistemas transaccionales tienden a poseer estructuras diseñadas para la gestión administrativa, no para el análisis matemático (Han et al., 2011). Se determinó que el sistema de gestión escolar registraba valores numéricos negativos (ej. -10.0 o -8.0) como banderas del sistema para representar evaluaciones no capturadas o inasistencias por baja temporal.

Se diseñó el módulo `data_cleaner.py`, encargado de iterar sobre el espacio vectorial de las métricas académicas para aplicar las siguientes reglas de limpieza:

1. Reemplazo de todo indicador estrictamente negativo (< 0) por la estructura nula estándar en ciencia de datos (NaN), evitando sesgar varianzas.
2. Eliminación de registros huérfanos que carecían de una matrícula válida para garantizar la consistencia topológica.

3.4. Ingeniería de características y estructuración temporal

Los algoritmos de aprendizaje automático requieren que la información capture la dinámica temporal del problema (Zheng and Casari, 2018). La metodología consistió en transformar transacciones individuales en perfiles acumulativos.

3.4.1. Anonimización criptográfica

Se implementó un algoritmo basado en la función hash criptográfica unidireccional *SHA-256* (National Institute of Standards and Technology (NIST), 2015). La función procesó la concatenación de la `matricula` y el `id_carrera` para generar una llave primaria subrogada (`alumno_carrera_hash`), permitiendo trazar el comportamiento longitudinal aislando los cambios de programa educativo.

3.4.2. Categorización semántica

Para evitar una matriz dispersa (*sparse matrix*) al procesar las asignaturas, se desarrolló un módulo basado en Expresiones Regulares (Regex). Las materias fueron clasificadas en áreas de conocimiento predefinidas (ej. *Matemáticas y Estadística*, *Programación y Computación*). Asimismo, el promedio de asistencia se discretizó en cinco bloques de riesgo ordinales (de Riesgo $< 80\%$ a Excelente $\geq 95\%$).

3.4.3. Construcción de instantáneas de progreso (Snapshots)

Para evitar el sesgo metodológico de fuga de información (*Data Leakage*), el comportamiento fue ordenado cronológicamente construyendo “instantáneas” iterativas por semestre. Por cada semestre cursado, se calcularon métricas acumulativas contemplando únicamente la ventana temporal permitida: promedios históricos, carga de materias reprobadas acumuladas y variabilidad del desempeño (desviación estándar).

3.4.4. Definición algorítmica de la variable objetivo (Target)

Ante la ausencia de una etiqueta administrativa explícita, se implementó una regla inferencial: se determinó el semestre máximo alcanzado por cada `alumno_carrera_hash`. Estudiantes con historiales que culminan o superan el décimo semestre fueron etiquetados con la clase positiva (1: Graduación/Retención), mientras que los historiales truncados prematuramente se etiquetaron con la clase negativa (0: Deserción).

4. Resultados del análisis exploratorio de datos

Una vez ejecutada la metodología descrita, se procedió a la evaluación empírica de los datos. Este capítulo expone los resultados del perfilado de la información transaccional cruda, la conformación poblacional final tras la ingeniería de características, y los hallazgos estadísticos bivariantes que caracterizan el fenómeno de la deserción.

4.1. Análisis estadístico descriptivo (Perfilado de datos crudos)

La extracción inicial consolidó un repositorio histórico de 133,882 registros de calificaciones. El análisis de cardinalidad sobre la variable identificadora determinó que la población base analizada asciende a 5,383 estudiantes físicos matriculados.

4.1.1. Variables temporales y de progresión

1. Año académico (`año_academico`) Representa el ciclo escolar macro. Su cobertura perfecta garantiza que ninguna calificación quede huérfana.

Cuadro 2: Métricas de calidad y distribución para `año_academico`

Métrica	Valor
Tipo de dato	Categorica
Valores distintos (Cardinalidad)	8 (< 0,1 %)
Datos faltantes (<i>Missing</i>)	0 (0,0 %)



Figura 1: Distribución de frecuencias por año académico

2 y 3. Periodos (`periodo` y `tipo_periodo`) La progresión limpia del identificador cronológico (Media: 47.86, IQR: 11) fue la columna vertebral que permitió ordenar los datos. El `tipo_periodo` fragmenta esta progresión en 3 clases distintas (Semestres regulares y curso de Verano).




Figura 2: Histograma de distribución de la variable periodo

4. Es periodo regular (es_periodo_regular) Bandera booleana donde Verdadero (True) representa el 98.4 % (131,679 registros). El 1.6 % restante corresponde a periodos extraordinarios, lo cual es altamente valioso como síntoma de rezago.

4.1.2. Ubicación curricular y programa educativo

5. Nombre del periodo (nombre_periodo) Posee 23 valores categóricos distintos y refleja una correlación biunívoca con el identificador numérico de periodo.

Value	Count	Frequency (%)
2020-2021A	9388	7.0%
2021-2022A	9285	6.9%
2020-2021B	8930	6.7%
2024-2025A	8617	6.4%
2019-2020A	8612	6.4%
2018-2019A	8465	6.3%
2017-2018A	8440	6.3%
2021-2022B	8064	6.0%
2023-2024A	8054	6.0%
2022-2023A	8035	6.0%
Other values (13)	47992	35.8%

Figura 3: Distribución de frecuencias por nombre del periodo

6 y 7. Semestre y tipo de semestre El semestre presenta una asimetría positiva de 0.37 (Media: 4.60, Mediana: 4). Esta concentración en grados tempranos es un reflejo directo del filtro de deserción escolar.




Figura 4: Histograma de distribución poblacional por semestre

8. Identificador de carrera (id_carrera) Se confirmó la presencia de transacciones provenientes de 12 programas educativos distintos (Mínimo: 2, Máximo: 13), evidenciando la necesidad de aislar su análisis mediante codificación.




Figura 5: Distribución transaccional por programa educativo

4.1.3. Identificadores institucionales y poblacionales

9, 10 y 11. Grupo, materia y matrícula Se detectó una alta cardinalidad operativa: 1,495 aulas/grupos distintos y 6,666 asignaturas únicas. La distribución de matrículas refleja a los 5,383 individuos físicos con una asimetría extrema derivada del formato de folio administrativo por año de ingreso.




Figura 6: Dispersión de Materias (Izq) y Matrículas (Der)

4.1.4. Evaluaciones académicas (Calificaciones)

Este bloque refleja la presencia de las anomalías detectadas. Los valores negativos actúan como banderas, y los ceros absolutos como métricas de abandono intrasemestral.

12, 13 y 14. Evaluaciones parciales (p1, p2, p3) Se observa una degradación progresiva de la media conforme avanza el ciclo: de 6.72 en el primer parcial a 6.55 en el tercero. Simultáneamente, la tasa de datos faltantes salta del 1.6 % en p1 al 6.0 % en los subsecuentes debido a extracciones en tiempo real. Los ceros absolutos suben del 1.3 % al 1.7 %.




Figura 7: Distribución de frecuencias: p1, p2 y p3

15. Examen ordinario (o) Presenta la dispersión estadística más alta del grupo regular (Varianza: 15.34). Los ceros absolutos alcanzan el 2.7%, consolidando el ordinario como el principal filtro terminal regular.




Figura 8: Distribución de frecuencias del examen ordinario

4.1.5. Métricas de asistencia y cumplimiento reglamentario

El reglamento de la UTM penaliza severamente con cero absoluto las calificaciones de quienes presenten una asistencia inferior al 80 % en el parcial correspondiente.

16, 17, 18 y 19. Asistencias parciales y ordinarias (a1, a2, a3, oa) La media de asistencia decae severamente: de 96.83 % en el primer parcial a 94.06 % en el tercero. Los ceros absolutos de asistencia se cuadruplican (del 0.5 % al 2.1 %), confirmando el abandono presencial de los estudiantes que perciben matemáticamente imposible aprobar la materia.




Figura 9: Decaimiento de la asistencia entre el primer y tercer parcial

4.1.6. Resultados finales y evaluaciones extraordinarias

20 y 21. Promedios finales (pf y pa) Tras procesar promedios, los valores negativos del sistema desaparecen. La asimetría negativa (-1.03) en pf indica que los

sobrevivientes del semestre tienden a aprobar, mientras la asistencia **pa** se estabiliza globalmente en 91.45 %.

22, 23 y 24. Evaluaciones de rescate (e1, e2, esp) Exhiben tasas masivas de datos faltantes lógicos (86.3 %, 92.1 % y 99.0 % respectivamente), confirmando el riguroso filtro institucional. El Examen Especial (**esp**), instancia de inminente expulsión, tiene una media de aprobación paupérrima de 1.62.




Figura 10: Deterioro poblacional en instancias extraordinarias y especiales

4.2. Resultados de la ingeniería de características

Tras aplicar la metodología de transformación, se obtuvieron las variables consolidadas que alimentarán a los algoritmos.

25. Perfil académico hasheado (alumno_carrera_hash) Al aplicar SHA-256, se obtuvieron 5,705 perfiles únicos. Contrastando con las 5,383 matrículas físicas, se prueba matemáticamente la existencia de 322 eventos de movilidad interna (cambio de carrera) en la institución.

Value	Count	Frequency (%)
4aa5139f0032cad090af6544...	79	0.1%
67e09839a6a1d3098db0360...	73	0.1%
023d810b3d49209b5521fff5...	72	0.1%
5ef3c2eeee1d3b3bad6e3e2...	67	0.1%
b0e71dbcba0d098eb7ac056...	66	< 0.1%
26e0d25827e71ef1f67e58de...	65	< 0.1%
c8138f11eed0f796dd612038...	65	< 0.1%
1c7306a200032c945d3c233...	65	< 0.1%
0e58158cfb10a30957645e7b...	65	< 0.1%
ac2c2417b0daf34bb5fbc935...	65	< 0.1%
Other values (5695)	133200	99.5%

Figura 11: Distribución uniforme de perfiles encriptados

26. Variable predictiva objetivo (resultado_final) La aplicación de la regla heurística sobre el semestre máximo arrojó un balance de clases óptimo para Machine Learning.

Cuadro 3: Distribución de la variable predictiva

Clase	Tipo de Dato	Población
1 (Graduado / Retención)	Booleana	$\approx 51,0 \%$
0 (Deserción)	Booleana	$\approx 49,0 \%$




Figura 12: Balance de clases de la variable predictiva

4.3. Análisis exploratorio bivariado (EDA)

Con el conjunto estructurado en *snapshots*, se evaluó la dependencia estadística entre los factores institucionales y el resultado final.

4.3.1. Correlación multivariable lineal

La Matriz de Correlación de Pearson evidenció una fuerte relación positiva del éxito estudiantil con el `promedio_asistencia_final` (0.50) y el `promedio_calificacion_final` (0.39), así como una penalización de -0.29 por la acumulación de materias reprobadas.




Figura 13: Matriz de correlación de variables institucionales

4.3.2. Estudio de varianza continua (ANOVA)

El estadístico F de Fisher confirmó contundentemente que la diferencia de promedios entre graduados y desertores es estadísticamente significativa ($p < 0,0001$).




Figura 14: Distribución ANOVA de Calificaciones (Izq) y Asistencias (Der)

4.3.3. Independencia categórica de la asistencia (χ^2)

Al cruzar la deserción con los bloques ordinales de asistencia, la prueba Chi-Cuadrada arrojó un estadístico de 2755.74 ($p < 0,0001$). El gráfico de barras apiladas al 100 % (Figura 15) evidencia un efecto de .escalera”: la deserción es inminente en la categoría de riesgo ($< 80\%$), mientras que la asistencia excelente ($\geq 95\%$) garantiza casi la totalidad de retención.




Figura 15: Tasa de retención estructurada por bloques de asistencia

5. Discusión de resultados

Este capítulo interpreta los hallazgos empíricos del Análisis Exploratorio, evaluando el peso predictivo real de las asignaturas y definiendo los umbrales críticos de fracaso institucional.

5.1. Fuerza predictiva y sesgos institucionales detectados

Para medir qué áreas de conocimiento protegen más al estudiante, se analizó inicialmente la correlación Punto-Biserial. Como ilustra la Figura 16, los resultados bivariados preliminares mostraron que áreas como *Administración y Gestión* o *Humanidades y Comunicación* presentaban una correlación aparente superior frente a las ciencias básicas, a pesar de tratarse de carreras tecnológicas.




Figura 16: Fuerza predictiva bruta de calificaciones por área de conocimiento

El análisis metodológico profundo reveló que este comportamiento respondía a un **Sesgo de supervivencia** de carácter exploratorio: dado que ciertas asignaturas se concentran en etapas posteriores de los planes de estudio, los estudiantes con reza- go severo ya habían abandonado la institución antes de cursarlas. En consecuencia, dicha correlación bivariada no reflejaba una causalidad protectora directa, sino un artefacto de la retención temporal que posteriormente fue controlado e intercepta- do mediante los modelos multivariados de regresión logística y árboles de decisión expuestos en las secciones subsecuentes.

5.2. Determinación de umbrales críticos y margen de rezago

Al aislar y corregir los sesgos, se determinó que el verdadero filtro de retención institucional son las ciencias básicas de los primeros semestres. El análisis de den- sidad (KDE) sobre el área de *Matemáticas y Estadística* evidenció el punto de no retorno:




Figura 17: Curvas de supervivencia y umbral en Ciencias Básicas

La intersección de las campanas señala que un promedio acumulado en matemáticas inferior a 6.5 multiplica la probabilidad estadística de pertenecer irreversiblemente a la población de desertores (área roja).




Figura 18: Tolerancia al rezago por área de conocimiento

Finalmente, el diagrama de cajas confirma que el margen de tolerancia institucional al error es sumamente estrecho. Los alumnos exitosos presentan invariablemente una mediana de cero reprobaciones en áreas troncales. La acumulación acelerada de materias no acreditadas detona matemáticamente el abandono de la institución.

6. Modelado explicativo: Regresión logística y razón de momios

Para trascender del análisis descriptivo a la cuantificación exacta del impacto institucional sobre la deserción, se implementó un modelo de Regresión Logística (Logit). La selección de este algoritmo se fundamenta en la naturaleza dicotómica de la variable objetivo (`resultado_final`).

6.1. Diagnóstico y eliminación de multicolinealidad (VIF)

Previo al ajuste del modelo, se evaluó el Factor de Inflación de la Varianza (VIF) para garantizar la independencia de las variables predictoras. Se estableció un umbral estricto de $VIF \leq 5,0$. El algoritmo detectó colinealidad perfecta ($VIF \rightarrow \infty$) en las variables de acumulación de materias reprobadas y en el promedio final global, ya que estas son combinaciones lineales de los promedios por área de conocimiento. Tras la depuración, la matriz de diseño conservó 15 características matemáticamente ortogonales y aptas para la regresión.




Figura 19: Análisis de multicolinealidad mediante Factor de Inflación de la Varianza (VIF)

6.2. Ajuste del modelo y significancia global

El modelo Logit convergió exitosamente mediante estimación de Máxima Verosimilitud (MLE). El estadístico de bondad de ajuste *Pseudo R-cuadrado de McFadden* arrojó un valor de **0.2949**. En el modelado de comportamiento humano y educativo, un Pseudo R^2 en el rango de 0.2 a 0.4 indica un ajuste excelente, confirmando que las variables institucionales seleccionadas tienen un alto poder explicativo sobre el fenómeno del abandono escolar en la UTM.

6.3. Extracción e interpretación de los Odds Ratios (Razón de momios)

La extracción de los *Odds Ratios* (e^β) permite traducir los coeficientes del modelo en reglas institucionales accionables. Se analizaron estrictamente aquellas variables con un Nivel de Significancia $P < 0,05$.

- **Cursos de Verano como mecanismo de resiliencia:** La variable estudiada `periodos_verano_cursados` se consolidó como el factor protector más fuerte

del modelo, con un *Odds Ratio* de **2.003**. Esto indica que los estudiantes que utilizan el periodo de verano para regularizarse tienen el doble de probabilidades matemáticas de culminar su carrera frente a sus pares que no lo hacen, validando la eficacia de este mecanismo institucional.

- **Penalización por Inestabilidad Académica:** La desviación estándar del desempeño (`std_calificacion_final`) arrojó un *Odds Ratio* de **0.544**. Esto se traduce en un factor de riesgo crítico: por cada punto de incremento en la inestabilidad de las calificaciones de un estudiante a lo largo de los semestres, sus probabilidades de titulación disminuyen de manera drástica en un **45.6 %** ($1,00 - 0,544$).
- **El axioma de la asistencia:** El `promedio_asistencia_final` demostró un *Odds Ratio* de **1.049**. Desde una perspectiva acumulativa, por cada punto porcentual (1 %) de mejora sostenida en la asistencia a las aulas, las probabilidades de éxito del estudiante se incrementan en un **5 %**.
- **Absorción del impacto en Ciencias Básicas:** De manera reveladora, las áreas de *Matemáticas y Estadística* y *Física y Química* perdieron significancia estadística pura ($P > 0,05$). Esto demuestra que el fracaso en estas materias "filtro" no actúa de forma aislada, sino que su impacto destructivo es absorbido y reflejado por la variable de inestabilidad general (`std_calificacion_final`).

El modelo explicativo confirma que la deserción en la UTM no es un evento repentino, sino el desenlace predecible de un deterioro progresivo en la constancia (asistencia) y la estabilidad del rendimiento del alumno.

6.4. Derivación de reglas de decisión institucional

Con el propósito de operacionalizar el modelo en un sistema de alerta temprana interpretable para el personal de tutorías, se entrenó un árbol de decisión de profundidad controlada ($max_depth = 3$). Las reglas lógicas derivadas del modelo permiten establecer perfiles de riesgo basados en umbrales de desempeño por área de conocimiento y constancia presencial.




Figura 20: Árbol de decisión: Reglas de riesgo institucional para la deserción

Como se observa en la jerarquía de decisión del modelo, la primera bifurcación crítica se detona en el rendimiento dentro del área de *Administración y Gestión* (con un umbral de corte de 5,97). Aquellos estudiantes que se ubican por debajo de este puntaje y que simultáneamente acumulan deficiencias en materias de ciencias exactas o ingeniería son clasificados de manera directa en la categoría de deserción (`class: 0`). Por el contrario, los alumnos que superan dicha retención inicial son evaluados a través de su constancia en el *promedio_asistencia_final* (estableciendo un límite operativo cercano al 90,5 %), separando el éxito terminal (`class: 1`) del rezago severo.

Este conjunto de reglas discretas aporta una estructura de “semáforo” analítico, permitiendo que la UTM detecte de forma proactiva y automatizada los momentos exactos de quiebre en la trayectoria escolar del alumnado.

Referencias

- Agrwal, L & Paik, A. (2015). A survey on data mining techniques for early prediction of student drop out. *International Journal on Computer Science and Engineering*, 7(7):61–70.
- Boswell, D. and Foucher, T. (2011). *The Art of Readable Code*. O'Reilly Media, Inc., Sebastopol, CA.
- Dijkstra, E. W. (1982). *Selected Writings on Computing: A Personal Perspective*. Springer-Verlag, New York.
- Fowler, M. (2002). *Patterns of Enterprise Application Architecture*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA.
- Han, J., Kamber, M., and Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition.

- Kuhn, M. and Johnson, K. (2013). *Applied Predictive Modeling*. Springer, New York.
- Martin, R. C. (2017). *Clean Architecture: A Craftsman's Guide to Software Structure and Design*. Prentice Hall, Boston, MA.
- Munson, T. (2011). *Data Preprocessing in Predictive Data Mining*. John Wiley & Sons, New Jersey.
- National Institute of Standards and Technology (NIST) (2015). Secure hash standard (shs). FIPS PUB 180-4, U.S. Department of Commerce.
- Parnas, D. L. (1972). On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, 15(12):1053–1058.
- Wiggins, A. (2011). *The Twelve-Factor App*. Accedido en mayo de 2026.
- Zheng, A. and Casari, A. (2018). *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. O'Reilly Media, Inc., Sebastopol, CA.