



Predicción de la deserción escolar con base en factores institucionales de los estudiantes de la UTM.

Presenta:

Méndez Luis Yakin Senen

Director de tesis:

Dr. Christian Eduardo Millán Hernández

Codirector de tesis:

M.T.C.A Moisés Emmanuel Ramírez
Guzmán

Lugar y fecha:

Heroica Ciudad de Huajuapam de León,
Oaxaca
Mayo de 2026

Resumen

La deserción estudiantil en la Universidad Tecnológica de la Mixteca (UTM), especialmente en los primeros semestres, representa un desafío institucional significativo. Ante la carencia de una herramienta para la intervención oportuna, esta investigación tiene como objetivo principal desarrollar un modelo predictivo. Mediante la aplicación de técnicas estadísticas y de aprendizaje automático, este estudio analiza factores institucionales—principalmente el historial de desempeño académico (calificaciones y asistencia)—para identificar patrones de riesgo. El resultado será una herramienta validada capaz de pronosticar la probabilidad de abandono, facilitando así estrategias de retención focalizadas.

Palabras clave:

Deserción escolar, educación superior, modelos predictivos, análisis institucional, aprendizaje automático, Universidad Tecnológica de la Mixteca

Índice

1. Introducción y planteamiento del problema	4
1.1. Situación actual	4
1.2. Problema central	4
1.3. Objetivo general	4
1.4. Objetivos específicos	5
1.5. Justificación	5
2. Marco teórico y estado del arte	6
2.1. La deserción escolar como fenómeno multicausal	6
2.1.1. El problema de la censura en el estudio de trayectorias escolares	6
2.2. Regresión logística y razón de momios en la investigación educativa .	7
2.3. Multicolinealidad y el Factor de Inflación de la Varianza (VIF)	7
2.4. Asociación entre variables categóricas: la V de Cramér	8
2.5. Árboles de decisión como modelos interpretables	8
2.6. Predicción dinámica y análisis por landmarks	8
2.7. El marco regulatorio institucional como fuente de definiciones operativas	9
3. Metodología: Adquisición, limpieza e ingeniería de características	10
3.1. Arquitectura del sistema de procesamiento	10
3.2. Extracción y conexión a la base de datos	10
3.3. Reglas de perfilado y saneamiento de datos crudos	11
3.4. Ingeniería de características y estructuración temporal	11
3.4.1. Anonimización criptográfica	11
3.4.2. Categorización semántica	11
3.4.3. Construcción de instantáneas de progreso (Snapshots)	12
3.4.4. Definición algorítmica de la variable objetivo (Target)	12
3.4.5. Redefinición de la censura mediante la ventana reglamentaria de permanencia	12
4. Resultados del análisis exploratorio de datos	14
4.1. Análisis estadístico descriptivo (Perfilado de datos crudos)	14
4.1.1. Variables temporales y de progresión	14
4.1.2. Ubicación curricular y programa educativo	15
4.1.3. Identificadores institucionales y poblacionales	16
4.1.4. Evaluaciones académicas (Calificaciones)	16
4.1.5. Métricas de asistencia y cumplimiento reglamentario	17
4.1.6. Resultados finales y evaluaciones extraordinarias	17
4.2. Resultados de la ingeniería de características	18
4.3. Análisis exploratorio bivariable (EDA)	19
4.3.1. Correlación multivariable lineal	19
4.3.2. Estudio de varianza continua (ANOVA)	20
4.3.3. Independencia categórica de la asistencia (χ^2)	20

5. Discusión de resultados	22
5.1. Fuerza predictiva y sesgos institucionales detectados	22
5.2. Determinación de umbrales críticos y margen de rezago	23
6. Metodología del modelado explicativo (Fase 2)	24
6.1. Selección de variables numéricas mediante VIF	24
6.2. Selección de variables categóricas mediante V de Cramér	24
6.3. Construcción de la matriz combinada y selección hacia atrás	25
6.4. Incorporación de las reglas institucionales de evaluación	25
6.5. Construcción de instantáneas por landmark	26
6.6. Derivación de reglas de riesgo legibles	26
7. Resultados del modelado explicativo (Fase 2)	27
7.1. Selección de variables numéricas (VIF)	27
7.2. Selección de variables categóricas (V de Cramér)	27
7.3. Modelo Logit combinado final	29
7.4. El cambio de carrera: un efecto mediado por el desempeño	30
7.5. Validación del desempeño de corto plazo	30
7.6. Árbol de decisión final y reglas de riesgo legibles	30
7.7. Instantáneas por landmark: cimiento para la Fase 3	32
7.8. Cierre de la Fase 2 y transición a la Fase 3	32
8. Metodología del modelado predictivo (Fase 3)	33
8.1. Dos diseños posibles: modelo único vs. modelos por landmark	33
8.2. Variables predictoras y fuga de información	33
8.3. División de entrenamiento y prueba por cohorte de ingreso	34
8.4. Modelos candidatos evaluados	34
8.5. Ajuste de hiperparámetros con validación cruzada agrupada por alumno	35
8.6. Optimización del umbral de decisión	35
8.7. Calibración de probabilidades	35
8.8. Comparación final: especialización por landmark (Opción A)	35
9. Resultados del modelado predictivo (Fase 3)	36
9.1. Comparación de modelos candidatos	36
9.2. Contraste justo: tuning de ambos finalistas	36
9.3. Optimización del umbral: un hallazgo sobre estabilidad temporal	38
9.4. Validación de la premisa dinámica: desempeño por landmark	39
9.5. Calibración de probabilidades	39
9.6. Opción A vs. Opción B: ¿ayuda especializar por landmark?	40
9.7. Cierre de la Fase 3	40
10. Limitaciones metodológicas y decisiones de alcance	41

1. Introducción y planteamiento del problema

1.1. Situación actual

La deserción escolar es un fenómeno persistente en la educación superior en México. La eficiencia terminal en la trayectoria profesional de los estudiantes se ve severamente afectada por el abandono temprano. Si bien los factores económicos tienen un peso importante, el rendimiento académico juega un rol preponderante y directo en la permanencia estudiantil.

A nivel institucional, la Universidad Tecnológica de la Mixteca (UTM) genera y almacena sistemáticamente un volumen considerable de datos transaccionales sobre sus estudiantes. Esta información incluye historiales de calificaciones por parcial, registros de asistencia, materias cursadas y la progresión semestral de cada alumno. Estos datos constituyen un registro objetivo y detallado del desempeño académico.

Actualmente, este repositorio de datos se utiliza principalmente para fines administrativos y de consulta de expedientes. Sin embargo, desde una perspectiva analítica, esta información puede ser analizada para el desarrollo de nuevas estrategias que permitan mejorar los programas de apoyo existentes, como el sistema de tutorías ya que este último opera sin un diagnóstico predictivo que les permita focalizar sus esfuerzos. La asignación de recursos de apoyo se basa en mecanismos reactivos, en lugar de estar informada por un análisis proactivo que identifique de manera automatizada a los estudiantes con mayor riesgo estadístico de abandono.

1.2. Problema central

Dada la situación actual, el problema central de esta investigación es la carencia de un modelo analítico validado que permita tanto explicar como predecir la deserción estudiantil en la UTM, basándose de manera exclusiva en factores institucionales.

Este problema se desglosa en dos componentes interrelacionados:

1. **La brecha explicativa:** Aunque existe la intuición de que el rendimiento académico influye en la deserción, la institución carece de un modelo explicativo que cuantifique la magnitud de cada factor. Se desconoce qué variables específicas (como el promedio o la constancia en asistencias) son los impulsores más fuertes del abandono.
2. **La brecha predictiva:** Como consecuencia directa, no existe una herramienta de pronóstico proactiva. La incapacidad de identificar a los estudiantes con alta probabilidad de desertar impide que los sistemas de tutoría se focalicen eficientemente.

1.3. Objetivo general

Modelar la relación entre los **factores institucionales** —restringidos exclusivamente a métricas de rendimiento académico tales como calificaciones y asistencias— y la deserción estudiantil en la UTM, para desarrollar un sistema de alerta temprana

que permita focalizar las estrategias de retención basándose en datos internos de la universidad.

1.4. Objetivos específicos

Para la consecución del objetivo general y bajo la delimitación de utilizar únicamente fuentes de información institucional, se plantean los siguientes objetivos específicos:

1. **(Fase Descriptiva)** Realizar un análisis estadístico descriptivo y exploratorio sobre el conjunto de datos históricos, enfocándose en la distribución y patrones de las variables institucionales.
2. **(Fase Explicativa)** Desarrollar modelos explicativos basados en análisis de multicolinealidad (VIF) y regresión logística para cuantificar la razón de momios (*Odds Ratios*) de los factores institucionales, complementados con árboles de decisión para la obtención de reglas de riesgo interpretables.
3. **(Fase Predictiva)** Diseñar, entrenar y validar un modelo predictivo de aprendizaje automático que utilice únicamente los registros académicos e institucionales para estimar la probabilidad de deserción.

1.5. Justificación

La relevancia de esta investigación radica en su potencial para generar un impacto directo y medible en la eficiencia académica y administrativa de la UTM. El proyecto se justifica desde dos perspectivas principales:

- **Justificación institucional y práctica:** El beneficio más directo es la optimización de los recursos institucionales. Al desarrollar un sistema de alerta temprana (semáforo), los programas de apoyo académico, como las tutorías y asesorías, podrán abandonar un esquema reactivo y adoptar un modelo proactivo.
- **Justificación metodológica y del conocimiento:** Este trabajo busca generar un conocimiento específico y contextualizado sobre el fenómeno de la deserción dentro de la UTM identificando los factores de riesgo únicos de esta población estudiantil, ajustado a la realidad de la institución ([Agrwal & Paik, 2015](#)).

2. Marco teórico y estado del arte

2.1. La deserción escolar como fenómeno multicausal

La deserción escolar en educación superior ha sido estudiada extensamente desde marcos teóricos que reconocen su naturaleza multicausal. El modelo de integración social y académica propuesto por Tinto (1975) sigue siendo el referente teórico dominante en el campo: postula que la permanencia estudiantil depende del grado de integración del alumno tanto al sistema académico (desempeño, involucramiento intelectual) como al sistema social de la institución. Revisiones posteriores del fenómeno en el contexto europeo (Kehm et al., 2019) y en distintos países de Latinoamérica (Vera et al., 2012; Miño de Gauto, 2021; Rose-Parra et al., 2023; Pérez-Jaimes et al., 2022; Gómez Morales, 2022; Gopar Rodríguez, 2023) confirman que, si bien los factores socioeconómicos son relevantes, el desempeño académico —calificaciones, asistencia y ritmo de avance curricular— constituye uno de los predictores más consistentes y, crucialmente, uno de los pocos que las instituciones pueden observar y accionar directamente sin depender de información externa al propio historial escolar del estudiante.

Desde la perspectiva computacional, la minería de datos educativa (*Educational Data Mining*) ha consolidado un cuerpo amplio de literatura sobre predicción de deserción mediante aprendizaje automático (Agrwal & Paik, 2015; Rastrollo-Guerrero et al., 2020; Prenkaj et al., 2020; Alban & Mauricio, 2019; Kovačić, 2010; Manrique et al., 2019). Sin embargo, dichas revisiones señalan de manera recurrente dos limitaciones metodológicas que este trabajo busca atender explícitamente: (i) la escasez de modelos **explicativos** que cuantifiquen la magnitud del efecto de cada factor —la mayoría reporta métricas de precisión predictiva sin traducirlas a razones de momios interpretables— y (ii) el tratamiento poco riguroso de la definición de la variable objetivo cuando esta se construye de forma heurística a partir de datos transaccionales, en lugar de a partir de una baja administrativa explícita.

2.1.1. El problema de la censura en el estudio de trayectorias escolares

Un reto metodológico frecuentemente subestimado en los estudios de deserción es el de la **censura**: cuando se analiza una base de datos histórica en un punto de corte fijo, una proporción de los estudiantes más recientes se encuentra todavía activa y su resultado final (graduación o abandono) es, en sentido estricto, desconocido. Este problema es análogo al que enfrenta el análisis de supervivencia en bioestadística, donde un paciente que continúa vivo al final del periodo de seguimiento no puede etiquetarse como “no falleció” de forma definitiva, sino como una observación **censurada por la derecha** (Kaplan & Meier, 1958). Tratar a un estudiante activo como un caso de deserción confirmada —únicamente porque aún no ha alcanzado el semestre de egreso— introduce un sesgo sistemático que infla artificialmente la tasa de abandono observada, un riesgo que rara vez se documenta explícitamente en la literatura de minería de datos educativa revisada.

2.2. Regresión logística y razón de momios en la investigación educativa

Cuando la variable de interés es dicotómica – como en este estudio, donde un estudiante se gradúa o deserta – el modelo estadístico apropiado es la regresión logística binaria, cuya formulación y propiedades inferenciales han sido ampliamente documentadas por [Hosmer et al. \(2013\)](#). A diferencia de la regresión lineal, la regresión logística modela el logaritmo de la razón de momios (*log-odds*) del desenlace como una combinación lineal de los predictores, garantizando que las probabilidades estimadas permanezcan acotadas entre 0 y 1:

$$\ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

El coeficiente exponenciado de cada predictor, e^{β} , se conoce como **razón de momios** (*Odds Ratio*) y cuantifica el cambio multiplicativo en los momios del desenlace por cada unidad de incremento en la variable predictora, manteniendo las demás constantes ([Szumilas, 2010](#)). Esta propiedad hace que la razón de momios sea particularmente valiosa en ciencias sociales y educativas, donde con frecuencia se requiere comunicar el efecto de un factor a tomadores de decisión no especializados en estadística sin sacrificar rigor matemático: [Peng et al. \(2002\)](#) documentan extensamente su uso e interpretación en la investigación educativa, señalando que la regresión logística es, junto con el análisis discriminante, el método preferido para modelar desenlaces educativos binarios (aprobación/reprobación, permanencia/deserción, admisión/rechazo) precisamente porque sus coeficientes admiten esta lectura directa en términos de “cuántas veces más probable resulta un desenlace”.

2.3. Multicolinealidad y el Factor de Inflación de la Varianza (VIF)

Un supuesto fundamental de los modelos de regresión (lineal o logística) es la ausencia de **multicolinealidad severa**: cuando dos o más predictores están altamente correlacionados entre sí, los coeficientes estimados se vuelven inestables, sus errores estándar se inflan artificialmente y la interpretación individual de cada variable pierde validez, aun cuando el modelo en su conjunto conserve poder predictivo. El **Factor de Inflación de la Varianza** (*Variance Inflation Factor*, VIF) cuantifica este problema: para cada predictor X_i se ajusta una regresión auxiliar contra el resto de los predictores y se calcula

$$VIF_i = \frac{1}{1 - R_i^2}$$

donde R_i^2 es el coeficiente de determinación de dicha regresión auxiliar. Un VIF_i elevado indica que X_i es explicada en gran medida por las demás variables del modelo. [O'Brien \(2007\)](#) revisa críticamente los umbrales convencionales (frecuentemente $VIF \leq 5$ o $VIF \leq 10$) y advierte que deben tratarse como heurísticas orientativas y no como reglas absolutas, dependientes del tamaño de muestra y del propósito inferencial del modelo – razón por la cual en este trabajo el umbral de $VIF \leq 5,0$ se

combinó sistemáticamente con una revisión conceptual de cada variable eliminada (Sección 7), en lugar de aplicarse de forma puramente mecánica.

2.4. Asociación entre variables categóricas: la V de Cramér

El VIF es apropiado para diagnosticar colinealidad entre variables numéricas, pero no es aplicable a predictores categóricos (nominales u ordinales) sin antes codificarlos, lo que puede ocultar redundancias reales. El análogo categórico utilizado en este trabajo es la **V de Cramér** (Cramér, 1946), una medida de asociación derivada del estadístico Chi-cuadrada de independencia que, a diferencia de este último, no depende del tamaño de la muestra y puede interpretarse como un tamaño de efecto acotado entre 0 (independencia total) y 1 (asociación perfecta):

$$V = \sqrt{\frac{\chi^2/n}{\min(k-1, r-1)}}$$

donde k y r son el número de categorías de cada variable. Se aplicó adicionalmente la corrección de sesgo propuesta por Bergsma (2013), necesaria porque la V de Cramér sin corregir tiende a sobrestimar la asociación en muestras finitas. La interpretación del tamaño de efecto siguió los umbrales convencionales de Cohen (1988), quien advierte – de forma análoga a lo señalado por O’Brien (2007) para el VIF – que con tamaños de muestra grandes casi cualquier asociación resulta estadísticamente significativa ($p < 0,05$) aunque su magnitud práctica sea trivial; por ello, la significancia estadística se combinó con un umbral mínimo de tamaño de efecto ($V \geq 0,05$) como criterio de conservación de variables.

2.5. Árboles de decisión como modelos interpretables

Mientras que la regresión logística cuantifica el efecto marginal de cada variable, los **árboles de decisión** – en su formulación CART (*Classification and Regression Trees*) de Breiman et al. (1984) y su antecesor conceptual ID3 (Quinlan, 1986) – particionan recursivamente el espacio de predictores en reglas del tipo “si-entonces” fácilmente traducibles a lenguaje natural. Esta propiedad los convierte en un complemento idóneo de la regresión logística para la construcción de sistemas de alerta temprana orientados a personal no técnico (p. ej., tutores académicos), donde la interpretabilidad de la regla es tan importante como su precisión estadística (Kuhn & Johnson, 2013).

2.6. Predicción dinámica y análisis por landmarks

Los modelos de deserción tradicionalmente asumen un único punto de evaluación (usualmente al final de un periodo académico). Sin embargo, cuando el objetivo es un sistema de alerta temprana operativo – como el que persigue este trabajo para el programa de Tutorías de la UTM –, la pregunta relevante cambia dinámicamente según el momento en que se realiza la consulta: la información disponible tras el primer parcial de un semestre es necesariamente distinta de la disponible al concluir

el tercero. Esta problemática ha sido formalizada en el análisis de supervivencia mediante la técnica de **landmarking** o predicción dinámica ([van Houwelingen, 2007](#)), que consiste en definir explícitamente uno o más puntos de referencia temporal (*landmarks*) y construir, para cada uno, un conjunto de variables predictoras que utilice **exclusivamente** la información disponible hasta ese punto, evitando así que información del futuro se filtre hacia el pasado (fuga de información temporal). Esta es la base conceptual adoptada en la Sección 6.5 para construir instantáneas alineadas con el calendario real de tutorías.

2.7. El marco regulatorio institucional como fuente de definiciones operativas

Un riesgo frecuente en la minería de datos educativa es la definición de reglas de negocio (qué constituye “aprobar”, “desertar” o “estar en riesgo”) de manera ad hoc, sin anclarlas a la normativa real de la institución de origen. En este trabajo, las reglas de aprobación de asignaturas, los mecanismos de recuperación (exámenes extraordinarios y especiales) y el tiempo límite de permanencia institucional se definieron con base en el *Reglamento de Alumnos de Licenciatura* ([Universidad Tecnológica de la Mixteca, 2024](#)), evitando introducir supuestos arbitrarios sobre el comportamiento del sistema escolar y anclando cada variable derivada a un artículo específico y verificable del reglamento vigente.

3. Metodología: Adquisición, limpieza e ingeniería de características

Dado el enfoque cuantitativo de esta investigación, la primera fase del proyecto consistió en la cimentación de una arquitectura de datos robusta. Para lograr predecir el riesgo de deserción, fue imperativo extraer, sanear y estructurar los datos transaccionales de la UTM para convertirlos en un conjunto de datos apto para algoritmos de aprendizaje automático.

3.1. Arquitectura del sistema de procesamiento

Para garantizar la reproducibilidad, escalabilidad y mantenibilidad del procesamiento de datos, se diseñó e implementó una arquitectura de software modular utilizando el lenguaje de programación Python (versión 3.13) operando dentro de un entorno virtual aislado (`venv`).

El diseño del sistema se fundamenta teóricamente en el paradigma de *Separación de intereses* (SoC), un principio de diseño arquitectónico postulado por [Dijkstra \(1982\)](#) y refinado por [Parnas \(1972\)](#). Asimismo, cada componente fue desarrollado bajo el *Principio de responsabilidad única* (SRP) descrito por [Martin \(2017\)](#).

Cuadro 1: Estructura modular del sistema de procesamiento y su fundamento de diseño

Módulo lógico	Responsabilidad algorítmica	Justificación arquitectónica
<code>db_connector.py</code>	Gestión del ciclo de vida de la conexión ORM y abstracción de consultas SQL.	Aislamiento de la capa de persistencia (Fowler, 2002).
<code>data_cleaner.py</code>	Detección, filtrado y transformación de banderas administrativas.	Capa de sanitización y pureza de datos (Munson, 2011).
<code>feature_engineer.py</code>	Anonimización criptográfica SHA-256 y cálculo de métricas acumulativas.	Capa de lógica de negocio y transformación matemática (Kuhn & Johnson, 2013).
<code>eda_visualizer.py</code>	Generación encapsulada de pruebas estadísticas (ANOVA, χ^2) y gráficos.	Desacoplamiento de la interfaz analítica y visual (Boswell & Foucher, 2011).

3.2. Extracción y conexión a la base de datos

La fuente primaria de información corresponde a la base de datos relacional de la UTM (PostgreSQL). Para salvaguardar la integridad de las credenciales, se adoptaron los principios de configuración de la metodología *Twelve-Factor App* ([Wiggins, 2011](#)).

La extracción de los datos históricos de los estudiantes se realizó construyendo un motor de conexión ORM a través de la biblioteca `SQLAlchemy` ([Fowler, 2002](#)). Se

ejecutó una consulta estructurada sobre el esquema `nes_public`, extrayendo calificaciones, asistencias y métricas de progresión académica.

3.3. Reglas de perfilado y saneamiento de datos crudos

Una vez concretada la extracción, se estableció un protocolo de perfilado utilizando la biblioteca `fg-data-profiling`. El objetivo metodológico fue inspeccionar la dimensionalidad y detectar valores fuera de dominio teórico antes de cualquier transformación.

El preprocesamiento es una etapa crítica, dado que los datos de sistemas transaccionales tienden a poseer estructuras diseñadas para la gestión administrativa, no para el análisis matemático (Han et al., 2011). Se determinó que el sistema de gestión escolar registraba valores numéricos negativos (ej. -10.0 o -8.0) como banderas del sistema para representar evaluaciones no capturadas o inasistencias por baja temporal.

Se diseñó el módulo `data_cleaner.py`, encargado de iterar sobre el espacio vectorial de las métricas académicas para aplicar las siguientes reglas de limpieza:

1. Reemplazo de todo indicador estrictamente negativo (< 0) por la estructura nula estándar en ciencia de datos (NaN), evitando sesgar varianzas.
2. Eliminación de registros huérfanos que carecían de una matrícula válida para garantizar la consistencia topológica.

3.4. Ingeniería de características y estructuración temporal

Los algoritmos de aprendizaje automático requieren que la información capture la dinámica temporal del problema (Zheng & Casari, 2018). La metodología consistió en transformar transacciones individuales en perfiles acumulativos.

3.4.1. Anonimización criptográfica

Se implementó un algoritmo basado en la función hash criptográfica unidireccional *SHA-256* (National Institute of Standards and Technology (NIST), 2015). La función procesó la concatenación de la `matricula` y el `id_carrera` para generar una llave primaria subrogada (`alumno_carrera_hash`), permitiendo trazar el comportamiento longitudinal aislando los cambios de programa educativo.

3.4.2. Categorización semántica

Para evitar una matriz dispersa (*sparse matrix*) al procesar las asignaturas, se desarrolló un módulo basado en Expresiones Regulares (Regex). Las materias fueron clasificadas en áreas de conocimiento predefinidas (ej. *Matemáticas y Estadística*, *Programación y Computación*). Asimismo, el promedio de asistencia se discretizó en cinco bloques de riesgo ordinales (de Riesgo $< 80\%$ a Excelente $\geq 95\%$).

3.4.3. Construcción de instantáneas de progreso (Snapshots)

Para evitar el sesgo metodológico de fuga de información (*Data Leakage*), el comportamiento fue ordenado cronológicamente construyendo “instantáneas” iterativas por semestre. Por cada semestre cursado, se calcularon métricas acumulativas contemplando únicamente la ventana temporal permitida: promedios históricos, carga de materias reprobadas acumuladas y variabilidad del desempeño (desviación estándar).

3.4.4. Definición algorítmica de la variable objetivo (Target)

Ante la ausencia de una etiqueta administrativa explícita, se implementó una regla inferencial basada en el semestre máximo alcanzado. La primera versión de esta regla presentaba, sin embargo, dos limitaciones metodológicas que fueron identificadas y corregidas antes de avanzar a la fase explicativa:

1. **Alcance institucional, no por programa:** un `alumno_carrera_hash` corresponde al par (matrícula, carrera), de modo que un estudiante que cambia de programa educativo genera dos identificadores distintos. Etiquetar el primero de ellos como deserción penalizaría injustamente a quien continuó y concluyó sus estudios en la segunda carrera, cuando la pregunta de interés institucional es la retención del alumno **dentro de la universidad**, no dentro de un programa específico. Por ello, la etiqueta `resultado_final` se recalculó a nivel de **matrícula (alumno físico)**, considerando el semestre máximo alcanzado en cualquiera de las carreras cursadas.
2. **Censura por la derecha:** dado que la base de datos se extrae en un punto de corte fijo, una proporción de los estudiantes más recientes se encuentra todavía cursando su carrera sin haber llegado al décimo semestre. Etiquetarlos como deserción sería incorrecto, pues su resultado real es aún desconocido (Sección 2.1.1). Se diseñó una bandera `es_censurado` que excluye del entrenamiento a todo alumno cuya actividad reciente y cuyo tiempo de permanencia se encuentren aún dentro de la ventana reglamentaria de la institución (Sección 3.4.5), reservando la etiqueta de deserción confirmada únicamente para quienes ya agotaron dicha ventana sin egresar.

3.4.5. Redefinición de la censura mediante la ventana reglamentaria de permanencia

Para determinar con mayor precisión qué estudiantes debían considerarse censurados, se recurrió nuevamente al *Reglamento de Alumnos de Licenciatura* (Universidad Tecnológica de la Mixteca, 2024). El Artículo 23 de dicho reglamento establece que el tiempo límite de permanencia como estudiante de licenciatura es el contemplado en el plan de estudios más dos años adicionales (con una posible extensión de un año más, sujeta a autorización del Consejo Académico). Un estudiante que no ha egresado, pero cuya última actividad es reciente y cuyo tiempo transcurrido desde su ingreso no excede dicha ventana reglamentaria, se etiquetó como censurado (resultado desconocido); en caso contrario – por reglamento la institución ya lo

habría dado de baja definitiva conforme al Artículo 19-II del mismo documento – se etiquetó como deserción confirmada.

Adicionalmente, el Artículo 10 del reglamento establece que el cambio de carrera es un derecho ejercible por una sola ocasión y únicamente durante los dos primeros semestres del programa que se abandona. Esta disposición se utilizó como criterio de validación cruzada de la variable `cambio_carrera` construida a partir de los datos (Sección 7).

4. Resultados del análisis exploratorio de datos

Una vez ejecutada la metodología descrita, se procedió a la evaluación empírica de los datos. Este capítulo expone los resultados del perfilado de la información transaccional cruda, la conformación poblacional final tras la ingeniería de características, y los hallazgos estadísticos bivariantes que caracterizan el fenómeno de la deserción.

4.1. Análisis estadístico descriptivo (Perfilado de datos crudos)

La extracción inicial consolidó un repositorio histórico de 133,882 registros de calificaciones. El análisis de cardinalidad sobre la variable identificadora determinó que la población base analizada asciende a 5,383 estudiantes físicos matriculados.

4.1.1. Variables temporales y de progresión

1. Año académico (`año_academico`) Representa el ciclo escolar macro. Su cobertura perfecta garantiza que ninguna calificación quede huérfana.

Cuadro 2: Métricas de calidad y distribución para `año_academico`

Métrica	Valor
Tipo de dato	Categorica
Valores distintos (Cardinalidad)	8 (< 0,1 %)
Datos faltantes (<i>Missing</i>)	0 (0,0 %)



Figura 1: Distribución de frecuencias por año académico

2 y 3. Periodos (`periodo` y `tipo_periodo`) La progresión limpia del identificador cronológico (Media: 47.86, IQR: 11) fue la columna vertebral que permitió ordenar los datos. El `tipo_periodo` fragmenta esta progresión en 3 clases distintas (Semestres regulares y curso de Verano).




Figura 2: Histograma de distribución de la variable periodo

4. Es periodo regular (es_periodo_regular) Bandera booleana donde Verdadero (True) representa el 98.4 % (131,679 registros). El 1.6 % restante corresponde a periodos extraordinarios, lo cual es altamente valioso como síntoma de rezago.

4.1.2. Ubicación curricular y programa educativo

5. Nombre del periodo (nombre_periodo) Posee 23 valores categóricos distintos y refleja una correlación biunívoca con el identificador numérico de periodo.

Value	Count	Frequency (%)
2020-2021A	9388	7.0%
2021-2022A	9285	6.9%
2020-2021B	8930	6.7%
2024-2025A	8617	6.4%
2019-2020A	8612	6.4%
2018-2019A	8465	6.3%
2017-2018A	8440	6.3%
2021-2022B	8064	6.0%
2023-2024A	8054	6.0%
2022-2023A	8035	6.0%
Other values (13)	47992	35.8%

Figura 3: Distribución de frecuencias por nombre del periodo

6 y 7. Semestre y tipo de semestre El semestre presenta una asimetría positiva de 0.37 (Media: 4.60, Mediana: 4). Esta concentración en grados tempranos es un reflejo directo del filtro de deserción escolar.




Figura 4: Histograma de distribución poblacional por semestre

8. Identificador de carrera (id_carrera) Se confirmó la presencia de transacciones provenientes de 12 programas educativos distintos (Mínimo: 2, Máximo: 13), evidenciando la necesidad de aislar su análisis mediante codificación.




Figura 5: Distribución transaccional por programa educativo

4.1.3. Identificadores institucionales y poblacionales

9, 10 y 11. Grupo, materia y matrícula Se detectó una alta cardinalidad operativa: 1,495 aulas/grupos distintos y 6,666 asignaturas únicas. La distribución de matrículas refleja a los 5,383 individuos físicos con una asimetría extrema derivada del formato de folio administrativo por año de ingreso.




Figura 6: Dispersión de Materias (Izq) y Matrículas (Der)

4.1.4. Evaluaciones académicas (Calificaciones)

Este bloque refleja la presencia de las anomalías detectadas. Los valores negativos actúan como banderas, y los ceros absolutos como métricas de abandono intrasemestral.

12, 13 y 14. Evaluaciones parciales (p1, p2, p3) Se observa una degradación progresiva de la media conforme avanza el ciclo: de 6.72 en el primer parcial a 6.55 en el tercero. Simultáneamente, la tasa de datos faltantes salta del 1.6% en p1 al 6.0% en los subsecuentes debido a extracciones en tiempo real. Los ceros absolutos suben del 1.3% al 1.7%.




Figura 7: Distribución de frecuencias: p1, p2 y p3

15. Examen ordinario (o) Presenta la dispersión estadística más alta del grupo regular (Varianza: 15.34). Los ceros absolutos alcanzan el 2.7 %, consolidando el ordinario como el principal filtro terminal regular.




Figura 8: Distribución de frecuencias del examen ordinario

4.1.5. Métricas de asistencia y cumplimiento reglamentario

El reglamento de la UTM penaliza severamente con cero absoluto las calificaciones de quienes presenten una asistencia inferior al 80 % en el parcial correspondiente.

16, 17, 18 y 19. Asistencias parciales y ordinarias (a1, a2, a3, oa) La media de asistencia decae severamente: de 96.83 % en el primer parcial a 94.06 % en el tercero. Los ceros absolutos de asistencia se cuadruplican (del 0.5 % al 2.1 %), confirmando el abandono presencial de los estudiantes que perciben matemáticamente imposible aprobar la materia.




Figura 9: Decaimiento de la asistencia entre el primer y tercer parcial

4.1.6. Resultados finales y evaluaciones extraordinarias

20 y 21. Promedios finales (pf y pa) Tras procesar promedios, los valores negativos del sistema desaparecen. La asimetría negativa (-1.03) en **pf** indica que los

sobrevivientes del semestre tienden a aprobar, mientras la asistencia `pa` se estabiliza globalmente en 91.45 %.

22, 23 y 24. Evaluaciones de rescate (`e1`, `e2`, `esp`) Exhiben tasas masivas de datos faltantes lógicos (86.3 %, 92.1 % y 99.0 % respectivamente), confirmando el riguroso filtro institucional. El Examen Especial (`esp`), instancia de inminente expulsión, tiene una media de aprobación paupérrima de 1.62.




Figura 10: Deterioro poblacional en instancias extraordinarias y especiales

4.2. Resultados de la ingeniería de características

Tras aplicar la metodología de transformación, se obtuvieron las variables consolidadas que alimentarán a los algoritmos.

25. Perfil académico hashado (`alumno_carrera_hash`) Al aplicar SHA-256, se obtuvieron 5,705 perfiles únicos. Contrastando con las 5,383 matrículas físicas, se prueba matemáticamente la existencia de 322 eventos de movilidad interna (cambio de carrera) en la institución.

Value	Count	Frequency (%)
4aa5139f0032cad090af6544...	79	0.1%
67e09839a6a1d3098db0360...	73	0.1%
023d810b3d49209b5521fff5...	72	0.1%
5ef3c2eeee1d3b3bad6e3e2...	67	0.1%
b0e71dbcba0d098eb7ac056...	66	< 0.1%
26e0d25827e71ef1f67e58de...	65	< 0.1%
c8138f11eed0f796dd612038...	65	< 0.1%
1c7306a200032c945d3c233...	65	< 0.1%
0e58158cfb10a30957645e7b...	65	< 0.1%
ac2c2417b0daf34bb5fbc935...	65	< 0.1%
Other values (5695)	133200	99.5%

Figura 11: Distribución uniforme de perfiles encriptados

26. Variable predictiva objetivo (`resultado_final`) Tras aplicar la corrección metodológica descrita en la Sección 3.4.5 (alcance institucional y censura por ventana reglamentaria), de los 5,383 alumnos físicos se identificaron 1,577 (29.3 %) como censurados – activos y dentro de su ventana reglamentaria de permanencia –, por lo

que se excluyeron del entrenamiento de los modelos explicativos y predictivos. Sobre los 3,806 alumnos restantes con resultado confirmado, la distribución de clases se mantuvo prácticamente balanceada:

Cuadro 3: Distribución de la variable predictiva (alumnos con resultado confirmado, $n = 3,806$)

Clase	Alumnos	Porcentaje
1 (Graduado / Retención)	1,944	51.08 %
0 (Deserción confirmada)	1,862	48.92 %




Figura 12: Balance de clases de la variable predictiva (referencia visual; los valores exactos posteriores a la corrección de censura se reportan en la tabla anterior)

De los 5,383 alumnos, 322 (5.98 %) exhibieron un cambio de carrera detectado mediante la comparación de perfiles hasheados (Párrafo 25). La validación cruzada contra el Artículo 10 del reglamento institucional (Sección 3.4.5) confirmó que el 95.6 % de estos casos (308 de 322) ocurrió, en efecto, dentro de los dos primeros semestres del programa abandonado, consistente con el derecho reglamentario correspondiente.

4.3. Análisis exploratorio bivariable (EDA)

Con el conjunto estructurado en *snapshots*, se evaluó la dependencia estadística entre los factores institucionales y el resultado final.

4.3.1. Correlación multivariable lineal

La Matriz de Correlación de Pearson evidenció una fuerte relación positiva del éxito estudiantil con el `promedio_asistencia_final` (0.50) y el `promedio_calificacion_final` (0.39), así como una penalización de -0.29 por la acumulación de materias reprobadas.

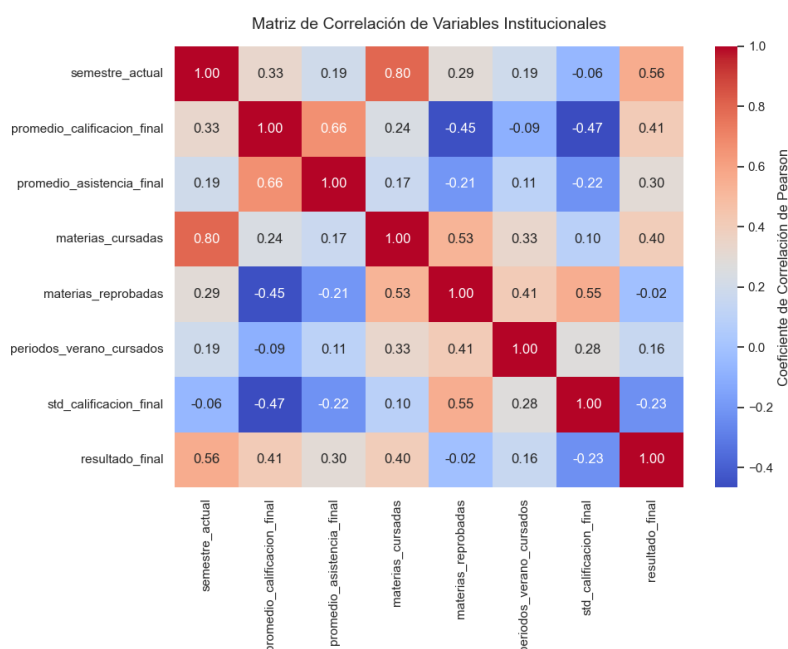


Figura 13: Matriz de correlación de variables institucionales

4.3.2. Estudio de varianza continua (ANOVA)

El estadístico F de Fisher confirmó contundentemente que la diferencia de promedios entre graduados y desertores es estadísticamente significativa ($p < 0,0001$).




Figura 14: Distribución ANOVA de Calificaciones (Izq) y Asistencias (Der)

4.3.3. Independencia categórica de la asistencia (χ^2)

Al cruzar la deserción con los bloques ordinales de asistencia, la prueba Chi-Cuadrada arrojó un estadístico de 2755.74 ($p < 0,0001$). El gráfico de barras apiladas al 100 % (Figura 15) evidencia un efecto de “escalera”: la deserción es inminente en la categoría de riesgo ($< 80\%$), mientras que la asistencia excelente ($\geq 95\%$) garantiza casi la totalidad de retención.




Figura 15: Tasa de retención estructurada por bloques de asistencia

5. Discusión de resultados

Este capítulo interpreta los hallazgos empíricos del Análisis Exploratorio, evaluando el peso predictivo real de las asignaturas y definiendo los umbrales críticos de fracaso institucional.

5.1. Fuerza predictiva y sesgos institucionales detectados

Para medir qué áreas de conocimiento protegen más al estudiante, se analizó inicialmente la correlación Punto-Biserial. Como ilustra la Figura 16, los resultados bivariantes preliminares mostraron que áreas como *Administración y Gestión* o *Humanidades y Comunicación* presentaban una correlación aparente superior frente a las ciencias básicas, a pesar de tratarse de carreras tecnológicas.




Figura 16: Fuerza predictiva bruta de calificaciones por área de conocimiento

El análisis metodológico profundo reveló que este comportamiento respondía a un **sesgo de supervivencia** de carácter curricular: dado que ciertas asignaturas se concentran en etapas posteriores de los planes de estudio, los estudiantes con rezago severo ya habían abandonado la institución antes de cursarlas.

Es importante documentar con honestidad metodológica que este sesgo resultó más persistente de lo que una primera corrección sugería. Al introducir una variable de *cobertura curricular* (fracción de las materias de una categoría ya cursadas respecto al total ofrecido en la carrera del alumno), pensada inicialmente para corregir el problema distinguiendo “aún no le toca” de “le fue mal”, el sesgo no desapareció: se intensificó. Las razones de momios de dichas variables alcanzaron magnitudes de hasta 10^{19} en iteraciones preliminares del modelo combinado, síntoma inequívoco de **separación cuasi-perfecta** (Hosmer et al., 2013) – haber cursado la totalidad de una categoría tardía del plan de estudios equivale, casi por definición, a haber llegado al final de la carrera, independientemente del desempeño real del estudiante en dicha área. En consecuencia, estas variables de cobertura se excluyeron explícitamente del modelo explicativo final mediante una regla de exclusión documentada en el código

(Sección 7), y su tratamiento adecuado se pospuso al enfoque de predicción dinámica por *landmarks* (van Houwelingen, 2007) desarrollado como cimiento de la Fase 3 (Sección 6.5), donde cada corte temporal compite únicamente con las asignaturas que el estudiante pudo haber cursado hasta ese punto. Este hallazgo ilustra que, en presencia de artefactos ligados a la posición curricular de una asignatura, ampliar el número de variables de un modelo multivariable no corrige por sí solo el sesgo de supervivencia: se requiere, adicionalmente, un criterio informado por el dominio del problema para decidir qué variables son legítimas de incluir.

5.2. Determinación de umbrales críticos y margen de rezago

Al aislar y corregir los sesgos, se determinó que el verdadero filtro de retención institucional son las ciencias básicas de los primeros semestres. El análisis de densidad (KDE) sobre el área de *Matemáticas y Estadística* evidenció el punto de no retorno:




Figura 17: Curvas de supervivencia y umbral en Ciencias Básicas

La intersección de las campanas señala que un promedio acumulado en matemáticas inferior a 6.5 multiplica la probabilidad estadística de pertenecer irreversiblemente a la población de desertores (área roja).




Figura 18: Tolerancia al rezago por área de conocimiento

Finalmente, el diagrama de cajas confirma que el margen de tolerancia institucional al error es sumamente estrecho. Los alumnos exitosos presentan invariablemente una mediana de cero reprobaciones en áreas troncales. La acumulación acelerada de materias no acreditadas detona matemáticamente el abandono de la institución.

6. Metodología del modelado explicativo (Fase 2)

Concluida la fase descriptiva, la segunda fase del proyecto tuvo como propósito cuantificar – no solo describir – el peso de cada factor institucional sobre la deserción, depurando el conjunto de variables candidatas mediante criterios estadísticos explícitos antes de ajustar el modelo explicativo final. La selección de un modelo de Regresión Logística (Logit) se fundamenta en la naturaleza dicotómica de la variable objetivo `resultado_final` (Hosmer et al., 2013).

6.1. Selección de variables numéricas mediante VIF

Sobre el conjunto de variables numéricas derivadas de los *snapshots* (promedios por área de conocimiento, desviación estándar del desempeño, materias reprobadas, periodos de verano cursados, entre otras), se calculó el VIF de cada candidata frente al resto, conservando únicamente aquellas con $VIF \leq 5,0$ (O'Brien, 2007). El procedimiento se automatizó como una función reutilizable del sistema (`calculate_vif`), de modo que pudiera aplicarse de manera consistente en iteraciones sucesivas conforme se incorporaron nuevas variables candidatas.

6.2. Selección de variables categóricas mediante V de Cramér

De manera análoga, las variables categóricas y ordinales (bloque de riesgo de asistencia, cohorte de ingreso, programa educativo, banderas de cambio y abandono de carrera, y el desempeño del semestre en curso) se evaluaron mediante una prueba Chi-cuadrada de independencia frente a `resultado_final` y su correspondiente V de Cramér con corrección de sesgo (Bergsma, 2013). Se estableció un criterio de

conservación doble: significancia estadística ($p < 0,05$) y un tamaño de efecto mínimo ($V \geq 0,05$), evitando conservar variables triviales que resultan “significativas” únicamente por el tamaño de la muestra (Cohen, 1988).

6.3. Construcción de la matriz combinada y selección hacia atrás

Las variables numéricas y categóricas que superaron sus respectivos filtros se combinaron en una única matriz de diseño. Las variables categóricas nominales (programa educativo, cohorte, banderas binarias) se codificaron mediante variables *dummy*; la variable ordinal de riesgo de asistencia se codificó como un único rango numérico (1 a 5) en lugar de *dummies*, para no fragmentar su categoría de referencia. Sobre esta matriz combinada se recalculó el VIF – las variables *dummy* pueden introducir colinealidad no evidente en el análisis univariado – y finalmente se ajustó un modelo Logit con **selección hacia atrás por p-valor** (*backward elimination*), eliminando iterativamente la variable menos significativa hasta que todas las restantes resultaron significativas al 5 %. Se prefirió este método sobre alternativas de regularización (p. ej. Lasso) porque conserva la interpretación directa de los coeficientes como razones de momios (Hosmer et al., 2013).

6.4. Incorporación de las reglas institucionales de evaluación

Para construir un target de corto plazo – complementario al de largo plazo (`resultado_final`) – alineado con la cadencia real del programa de Tutorías (una revisión por cada periodo parcial), se operacionalizó la regla de aprobación de una asignatura directamente a partir del *Reglamento de Alumnos de Licenciatura* (Universidad Tecnológica de la Mixteca, 2024):

- Aprobación por evaluación ordinaria: calificación final $\geq 6,0$ y asistencia $\geq 85\%$ (Artículos 52 y 29-XI/50-I).
- Aprobación por examen extraordinario (primero o segundo): calificación $\geq 6,0$ (Artículos 62-65).
- Aprobación por examen especial: calificación $\geq 6,0$, aplicable únicamente tras un recursamiento (Artículo 69).

La variable `aprobo_semestre` se definió como el cumplimiento de esta regla en la totalidad de las asignaturas cursadas **dentro del semestre en curso**, y `materias_reprobadas_este_semestre` como su conteo complementario. Ambas variables se sometieron al mismo proceso de selección categórica/numérica descrito anteriormente, para verificar si aportaban información independiente de las variables acumuladas de largo plazo.

Para determinar si una inscripción correspondía a un recursamiento – información necesaria para la regla del examen especial – se requirió superar una limitación del sistema de origen: el identificador de materia (`id_materia`) se regenera en cada oferta/periodo y no identifica de forma estable la misma asignatura a través del

tiempo. Se evaluó una estrategia de coincidencia difusa por similitud de tokens del nombre de la materia, la cual se descartó por generar fusiones incorrectas entre asignaturas distintas que comparten palabras genéricas (p. ej. “Cálculo Diferencial” y “Cálculo Integral”, o “Estructuras de Acero” y “Estructuras de Concreto”); se optó en su lugar por una coincidencia **exacta** tras normalizar el nombre (mayúsculas, acentos y conectores), una decisión deliberadamente conservadora que subestima el recursamiento en casos de renombre semántico de la asignatura antes que arriesgar falsos positivos (Sección 10).

6.5. Construcción de instantáneas por landmark

Como cimiento explícito para el sistema de alerta temprana de la Fase 3, se construyó una variante de la instantánea de progreso alineada con los tres momentos reales en que el programa de Tutorías revisa a cada estudiante dentro de un semestre: al concluir el primer parcial, al concluir el segundo, y al concluir el tercero (antes de la evaluación ordinaria). Siguiendo el principio de predicción dinámica por *landmarks* (van Houwelingen, 2007), cada instantánea utiliza exclusivamente la información disponible hasta ese punto: los semestres ya concluidos aportan su calificación final real, mientras que el semestre en curso aporta el promedio de los parciales ya presentados como estimador provisional de desempeño – nunca la calificación final, que aún no existe en ninguno de los tres momentos. El desenlace a predecir (`aprobo_semestre`, `resultado_final`) se mantiene fijo entre los tres landmarks de un mismo semestre, dado que corresponde a información conocida solo en retrospectiva y nunca debe filtrarse hacia las variables predictoras.

6.6. Derivación de reglas de riesgo legibles

Con el propósito de traducir el árbol de decisión final en un insumo utilizable por personal no técnico, se desarrolló una rutina que recorre la estructura interna del árbol entrenado y traduce cada hoja en una regla en lenguaje natural, acompañada de la probabilidad de graduación observada en los casos históricos que satisfacen dicha regla y una clasificación semafórica (Verde $\geq 75\%$, Amarillo entre 50% y 75%, Rojo $< 50\%$) alineada con los tres niveles de intervención descritos en la Sección 1.5.

7. Resultados del modelado explicativo (Fase 2)

7.1. Selección de variables numéricas (VIF)

Del conjunto inicial de 33 variables numéricas candidatas, el filtro de VIF conservó 15, eliminando de manera esperada las variables de conteo agregado (`materias_cursadas_totales`, `promedio_calificacion_final`) por ser combinaciones lineales de los promedios desagregados por área de conocimiento, así como el desempeño previo a un cambio de carrera (`pf_previo_a_cambio`, `pa_previo_a_cambio`), redundante con las métricas acumuladas generales.




Figura 19: Análisis de multicolinealidad (VIF) sobre el conjunto de variables numéricas actualizado

7.2. Selección de variables categóricas (V de Cramér)

Las seis variables categóricas candidatas superaron el umbral de tamaño de efecto, con `aprobo_semestre` (el desempeño del semestre en curso) como la de mayor asociación individual con la deserción ($V = 0,503$), seguida de la cohorte de ingreso ($V = 0,420$) y el bloque de riesgo de asistencia ($V = 0,367$).

Cuadro 4: Selección de variables categóricas mediante V de Cramér

Variable	χ^2	V de Cramér	Estado
<code>aprobo_semestre</code>	4,908.36	0.503	Conservada
<code>cohorte_ingreso</code>	3,421.35	0.420	Conservada
<code>categoria_asistencia</code>	2,614.05	0.367	Conservada
<code>id_carrera</code>	502.72	0.159	Conservada
<code>carrera_abandonada</code>	361.77	0.137	Conservada
<code>cambio_carrera</code>	166.53	0.093	Conservada




Figura 20: Relevancia de variables categóricas frente a la deserción (V de Cramér)

La matriz de asociación entre las variables categóricas conservadas (Figura 21) descartó redundancia severa entre ellas: la asociación cruzada más alta se observó, de manera esperada, entre `cambio_carrera` y `carrera_abandonada` ($V = 0,49$, pues la segunda es un subconjunto de la primera), sin alcanzar un nivel que justificara excluir alguna de las dos.




Figura 21: Matriz de asociación (V de Cramér) entre variables categóricas conservadas

7.3. Modelo Logit combinado final

El modelo combinado final, ajustado sobre 19,406 instantáneas semestrales correspondientes a 3,806 alumnos con resultado confirmado, convergió con un Pseudo R^2 de McFadden de **0.4742** – sustancialmente superior al 0.2949 obtenido en una iteración preliminar exclusivamente numérica –, confirmando que la incorporación de las variables categóricas y del desempeño de corto plazo incrementó de forma sustancial el poder explicativo del modelo. De las 19 variables predictoras que sobrevivieron la selección hacia atrás, la totalidad resultó estadísticamente significativa ($p < 0,05$).

Cuadro 5: Odds Ratios del modelo Logit combinado final (variables significativas, $p < 0,05$)

Variable	Odds Ratio	IC 95 %	$P > z $
Carrera abandonada	1.776	[1.245, 2.533]	0.002
Aprobó el semestre en curso	1.710	[1.463, 1.998]	< 0,001
Periodos de verano cursados	1.584	[1.409, 1.781]	< 0,001
Promedio en Automatización y Robótica	1.434	[1.291, 1.593]	< 0,001
Promedio en Administración y Gestión	1.283	[1.243, 1.325]	< 0,001
Promedio en Materiales y Procesos	1.168	[1.144, 1.193]	< 0,001
Promedio en Electrónica y Control	1.141	[1.120, 1.162]	< 0,001
Promedio en Matemáticas y Estadística	1.138	[1.114, 1.162]	< 0,001
Promedio en Ingeniería Mecánica	1.122	[1.100, 1.144]	< 0,001
Promedio en Humanidades y Comunicación	1.103	[1.060, 1.148]	< 0,001
Promedio en Diseño y Arquitectura	1.091	[1.073, 1.109]	< 0,001
Promedio en otras áreas	1.083	[1.053, 1.114]	< 0,001
Promedio en Economía y Finanzas	1.072	[1.034, 1.113]	< 0,001
Categoría de riesgo de asistencia (ordinal)	0.916	[0.865, 0.969]	0.002
Cambio de carrera	0.751	[0.600, 0.940]	0.012
Cohorte de ingreso 2019-2020	0.665	[0.578, 0.765]	< 0,001
Materias reprobadas este semestre	0.643	[0.611, 0.678]	< 0,001
Desviación estándar de calificaciones	0.588	[0.545, 0.633]	< 0,001
Cohorte de ingreso 2020-2021	0.430	[0.369, 0.500]	< 0,001

El procedimiento de selección hacia atrás eliminó seis variables candidatas. Tres de ellas – las cohortes de ingreso 2021-2022, 2022-2023 y 2023-2024 – mostraron p -valores cercanos a 1.0, síntoma de **separación cuasi-perfecta** (Hosmer et al., 2013): dado que el periodo más reciente del dataset es 2024-2025B, estructuralmente ningún estudiante de esas cohortes ha tenido tiempo suficiente para alcanzar el décimo semestre, lo que impide estimar de forma estable el coeficiente correspondiente. Las tres variables restantes (cohorte 2018-2019, y los promedios en Programación y Computación y en Física y Química) se eliminaron por no alcanzar significancia estadística convencional una vez controlado por el resto de las variables del modelo, lo cual es esperable dada su correlación con otras métricas de desempeño ya incluidas. El patrón monótono decreciente observado en las cohortes que sí permanecieron

en el modelo (2019-2020: $OR = 0,665$; 2020-2021: $OR = 0,430$) es consistente con la explicación de separación cuasi-perfecta: refleja la ventana de tiempo disponible para egresar, no una tendencia real de deterioro generacional en el desempeño estudiantil, y debe interpretarse con esta salvedad.

7.4. El cambio de carrera: un efecto mediado por el desempeño

La interpretación conjunta de las variables `cambio_carrera` y `carrera_abandonada` arroja un hallazgo sustantivo para la discusión institucional. Considerando únicamente el desempeño académico acumulado, `carrera_abandonada` no alcanzaba significancia estadística en iteraciones preliminares del modelo, sugiriendo que el riesgo elevado observado en el análisis bivariable para los estudiantes que cambian de programa era explicado en su totalidad por su rendimiento previo, no por el cambio en sí. Sin embargo, al incorporar el desempeño del semestre en curso (`aprobo_semestre`, `materias_reprobadas_este_semestre`) como control adicional, `carrera_abandonada` recuperó significancia ($OR = 1,776$), mientras que `cambio_carrera` en sí mismo se mantuvo con un efecto protector ($OR = 0,751$). La lectura conjunta es la siguiente: el riesgo del cambio de carrera no reside en el promedio histórico del estudiante, sino en su desempeño inmediato alrededor del momento del cambio; una vez que dicho estudiante logra establecerse en su nuevo programa, su trayectoria deja de estar penalizada e incluso resulta ligeramente protectora frente a quien nunca se cambió.

7.5. Validación del desempeño de corto plazo

Las variables de corto plazo (`aprobo_semestre`, `materias_reprobadas_este_semestre`) sobrevivieron tanto el filtro de multicolinealidad como la selección hacia atrás, con Odds Ratios de 1.710 y 0.643 respectivamente – es decir, aportan información sobre la deserción final que no está contenida en las variables acumuladas de largo plazo. Este resultado valida empíricamente la pertinencia de construir, además del modelo de largo plazo, un indicador de desempeño inmediato alineado con la cadencia de las revisiones de Tutorías.

7.6. Árbol de decisión final y reglas de riesgo legibles

El árbol de decisión ajustado sobre el mismo conjunto de variables del modelo Logit final (profundidad máxima de 3) seleccionó como primera bifurcación precisamente `materias_reprobadas_este_semestre` – coincidiendo con la variable de mayor tamaño de efecto categórico (V de Cramér) y aportando una validación cruzada entre ambos métodos.




Figura 22: Árbol de decisión final sobre el conjunto de variables combinado

La traducción de cada hoja del árbol en una regla legible con su probabilidad de graduación observada (Tabla 6) constituye el insumo directo para el semáforo de alerta temprana descrito en la Sección 1.5.

Cuadro 6: Reglas de riesgo interpretables derivadas del árbol de decisión final

Regla	Alumnos	Prob. Grad.	Semáforo
> 1 materia reprobada este semestre; promedio en Matemáticas $\leq 4,96$; promedio en Administración $\leq 5,11$	1,879	10.4 %	Rojo
> 1 materia reprobada este semestre; promedio en Matemáticas > 4,96; promedio en Administración $\leq 2,09$	1,114	42.9 %	Rojo
> 1 materia reprobada este semestre; promedio en Matemáticas $\leq 4,96$; promedio en Administración > 5,11	142	57.8 %	Amarillo
1 materia reprobada este semestre; promedio en Electrónica $\leq 3,96$	1,763	64.7 %	Amarillo
> 1 materia reprobada este semestre; promedio en Matemáticas > 4,96; promedio en Administración > 2,09	465	83.2 %	Verde
0-1 materias reprobadas este semestre; promedio en Electrónica $\leq 4,25$	6,834	88.6 %	Verde
1 materia reprobada este semestre; promedio en Electrónica > 3,96	891	89.8 %	Verde
0 materias reprobadas este semestre; promedio en Electrónica > 4,25	6,318	98.0 %	Verde




Figura 23: Reglas de riesgo del árbol de decisión final, clasificadas en semáforo

7.7. Instantáneas por landmark: cimiento para la Fase 3

La construcción de instantáneas por landmark (Sección 6.5) generó 58,218 registros – exactamente el triple de las 19,406 instantáneas semestrales, una por cada uno de los tres landmarks –, sobre los cuales se verificó que el desenlace real (`aprobo_semestre`, `resultado_final`) permanece constante dentro de cada terna de landmarks de un mismo alumno y semestre, mientras que las variables predictoras evolucionan conforme se conoce más información (p. ej., el promedio de calificación acumulado de un caso de referencia varió de 7.44 a 7.41 y finalmente a 7.35 conforme se incorporaron los tres parciales). Esta estructura de datos, ya validada, es la que alimentará el diseño de los modelos predictivos dinámicos de la Fase 3.

7.8. Cierre de la Fase 2 y transición a la Fase 3

Los resultados de esta fase confirman que la deserción en la UTM puede explicarse en una proporción sustancial (Pseudo R^2 de McFadden = 0,4742) mediante factores exclusivamente institucionales, sin recurrir a información socioeconómica o demográfica. El conjunto de variables validado – desempeño acumulado por área de conocimiento, constancia (desviación estándar), asistencia, cohorte y desempeño de corto plazo –, junto con las reglas de riesgo interpretables de la Tabla 6, constituye el punto de partida directo para el diseño de los modelos predictivos de la Fase 3, los cuales deberán resolver el reto adicional identificado en la Sección 6.5: producir una estimación de riesgo distinta en cada uno de los tres momentos de revisión de Tutorías, en lugar de un único modelo estático.

8. Metodología del modelado predictivo (Fase 3)

A diferencia de la Fase 2 – centrada en **explicar** el peso de cada factor institucional mediante modelos interpretables (Logit, árbol de decisión) –, la Fase 3 persigue **poder predictivo puro**, sin restricción de interpretabilidad: la preselección de variables, el descarte de fugas de información y la infraestructura de instantáneas por landmark (Sección 6.5) construidas en las fases previas son los cimientos directos sobre los que se construye esta fase.

8.1. Dos diseños posibles: modelo único vs. modelos por landmark

Se evaluaron dos formas de incorporar los 3 momentos de revisión de Tutorías (`landmark_parcial` 1, 2 y 3) al modelo predictivo:

- **Opción A:** un modelo independiente por cada landmark, entrenado únicamente con las instantáneas de ese momento.
- **Opción B:** un único modelo entrenado sobre las 58,218 instantáneas completas, incorporando `landmark_parcial` como una variable explícita más.

Se implementó primero la Opción B, para no penalizar con menos datos de entrenamiento justo al landmark más débil y operativamente más valioso – el primero, que ofrece a Tutorías el mayor margen de reacción pero es también el que cuenta con menos información acumulada. La Opción A se reservó como comparación empírica una vez validada por completo la Opción B (Sección 9).

8.2. Variables predictoras y fuga de información

Algunas variables legítimas como predictoras explicativas en la Fase 2 no pueden emplearse en un modelo dinámico por landmark:

- `aprobo_semestre` y `materias_reprobadas_este_semestre` se calculan con el `aprobo_materia` real de fin de semestre (Sección 6.5), por lo que permanecen constantes en los 3 landmarks de un mismo semestre – son la etiqueta de corto plazo, no información disponible en el landmark 1 o 2. Usarlas como predictoras constituiría una fuga de información hacia el pasado.
- Las variables `cobertura_*` se mantienen excluidas por la separación cuasi-perfecta ya documentada en la Fase 2 (Sección 10): es una fuga real del proceso generador de los datos, no una simple colinealidad que los ensembles de árboles puedan tolerar mejor que el Logit.
- `cohorte_ingreso` se excluye como **predictora** (aunque se sigue usando para dividir entrenamiento y prueba, ver más abajo): conservarla como variable rompería el objetivo de simular generaciones futuras, dado que una cohorte real aún no vivida jamás tendrá una categoría ya vista por el modelo.

Al no requerir interpretabilidad, `id_carrera` sí puede incorporarse por completo: en la Fase 2 se excluyó del Logit combinado únicamente por causar un Hessiano singular al combinarse con los dummies de cohorte (Sección 7), una limitación exclusiva de la regresión que no afecta a los modelos de árbol/ensemble ni a una Regresión Logística regularizada.

8.3. División de entrenamiento y prueba por cohorte de ingreso

En vez de un particionamiento aleatorio, las instantáneas se dividieron según `cohorte_ingreso` para simular la predicción sobre generaciones futuras – el escenario real de un sistema de alerta temprana desplegado en producción. Se entrenó con las cohortes 2017-2018 a 2019-2020 (48,726 instantáneas, 83.7%) y se evaluó sobre las cohortes 2020-2021 en adelante (9,492 instantáneas, 16.3%), nunca vistas durante el ajuste de ningún modelo. Esta partición incluye deliberadamente la cohorte 2020-2021 (afectada por la pandemia, con un Odds Ratio de 0.430 en la Fase 2 – Tabla 5) como una prueba honesta y exigente de generalización a una generación estadísticamente distinta de las de entrenamiento. Por tratarse de una propiedad fija de cada alumno, dividir por cohorte garantiza además que ningún estudiante aparezca simultáneamente en entrenamiento y prueba.

8.4. Modelos candidatos evaluados

Se compararon cinco algoritmos de aprendizaje supervisado sobre el mismo split: **Random Forest**, **LightGBM**, **XGBoost** y **CatBoost** (cuatro variantes de ensembles de árboles), junto con una **Regresión Logística** como línea base lineal – para cuantificar cuánto aporta realmente la complejidad de los ensembles sobre un modelo lineal directo con el mismo conjunto de variables. CatBoost se evaluó con una matriz de diseño alternativa que conserva `id_carrera` como texto en vez de variables dummy, aprovechando su soporte nativo de variables categóricas.

Se descartaron como candidatos SVM, KNN y Naive Bayes: la evidencia empírica es consistente en que rinden peor que el boosting de árboles en datos tabulares de este tamaño y mezcla de variables, sin aportar ninguna ventaja que el boosting no cubra ya. De igual forma, se descartó una red neuronal genérica (*Multi-Layer Perceptron*): la literatura reciente documenta que, en datos tabulares de este volumen y naturaleza (variables numéricas y categóricas mixtas, sin estructura de imagen, texto o secuencia), el boosting de árboles y los modelos lineales regularizados igualan o superan a las redes neuronales profundas, con un costo de ajuste y una necesidad de datos considerablemente menores (Grinsztajn et al., 2022; Shwartz-Ziv & Armon, 2022). Un enfoque de secuencia (LSTM/GRU o Transformer) sobre la trayectoria semestre-a-semestre completa del alumno sí sería conceptualmente distinto – y se documenta como línea de trabajo futuro en la Sección 10 – pero excede el alcance de esta tesis.

8.5. Ajuste de hiperparámetros con validación cruzada agrupada por alumno

Los dos candidatos con mejor desempeño de línea base (Sección 9) se afinaron mediante `RandomizedSearchCV`, usando `StratifiedGroupKFold` agrupado por `alumno_carrera_hash`: cada alumno aporta varias instantáneas (una por semestre por landmark), y no debe quedar repartido entre el pliegue de entrenamiento y el de validación dentro del CV, o el ajuste heredaría la misma fuga que ya se evitó en la partición por cohorte. Se optimizó sobre el área bajo la curva de precisión-recall (PR-AUC) de la clase **Deserción** – la clase minoritaria (21 % de los casos) y la que le importa a un sistema de alerta temprana – en vez de accuracy o ROC-AUC. Para la Regresión Logística, la búsqueda incluyó tanto la fuerza de regularización (C) como el tipo de penalización (L1 o L2); la penalización L1 tiene el beneficio adicional de llevar a cero los coeficientes de las variables menos relevantes, funcionando como un mecanismo de selección de variables incorporado (Tibshirani, 1996).

8.6. Optimización del umbral de decisión

El umbral de clasificación por defecto (0.5) no tiene ninguna razón estadística especial de ser el óptimo, sobre todo con clases desbalanceadas. Se buscó el umbral que maximiza el F1 de la clase Deserción usando probabilidades *out-of-fold* del mismo procedimiento de validación cruzada agrupada, calculadas únicamente sobre el conjunto de entrenamiento – nunca sobre prueba, para no contaminar la evaluación final con una decisión ajustada a esos datos.

8.7. Calibración de probabilidades

Más allá de la clase predicha, un sistema de alerta temprana real puede requerir el puntaje de riesgo (probabilidad) directamente para priorizar casos. Se evaluó la calibración del modelo final mediante una curva de confiabilidad (probabilidad predicha vs. fracción observada, por deciles) y el *Brier score*, dado que un modelo con buen poder discriminativo (ROC-AUC alto) puede seguir estando mal calibrado.

8.8. Comparación final: especialización por landmark (Opción A)

Con la Opción B completamente validada, se resolvió la comparación pendiente: se entrenaron 3 modelos de Regresión Logística independientes, uno por landmark, siguiendo exactamente el mismo procedimiento de ajuste y validación cruzada que el modelo final de la Opción B – misma familia de algoritmo, para aislar la pregunta de esta comparación (¿ayuda especializar por landmark?) de la pregunta ya resuelta en la comparación de candidatos (¿qué algoritmo es mejor?). Cada modelo de la Opción A entrena con un tercio de las instantáneas de entrenamiento (16,242 de 48,726) y sin `landmark_parcial` como variable, al ser una columna constante dentro de un único landmark.

9. Resultados del modelado predictivo (Fase 3)

9.1. Comparación de modelos candidatos

La Tabla 7 resume el desempeño de línea base (antes de cualquier ajuste de hiperparámetros) de los cinco candidatos sobre las cohortes de prueba, nunca vistas durante el entrenamiento.

Cuadro 7: Desempeño de línea base de los modelos candidatos (Fase 3, sin tuning)

Modelo	ROC-AUC	PR-AUC	Precisión	Recall	F1
Regresión Logística	0.9665	0.9616	0.8654	0.9097	0.8870
XGBoost	0.9558	0.9515	0.8801	0.8434	0.8614
CatBoost	0.9561	0.9520	0.8725	0.8629	0.8677
Random Forest	0.9554	0.9518	0.9841	0.5823	0.7317
LightGBM	0.9532	0.9492	0.8804	0.8317	0.8554

Precisión, Recall y F1 corresponden a la clase Deserción (0).

El resultado más relevante de esta tabla no es cuál ensemble de árboles rinde mejor entre sí, sino que **la Regresión Logística, sin ningún ajuste, ya supera a los cuatro ensembles de árboles**. Random Forest ilustra además por qué el ROC-AUC por sí solo puede ser engañoso: alcanza una precisión de 0.984, pero un recall de apenas 0.582 – deja pasar 4 de cada 10 desertores reales sin alertar, justo el error más costoso para un sistema de alerta temprana.

9.2. Contraste justo: tuning de ambos finalistas

Antes de aceptar el resultado anterior como conclusión, se le dio a la Regresión Logística la misma oportunidad de ajuste que a XGBoost (el mejor ensemble de árboles), mediante el procedimiento descrito en la Sección 8. La Tabla 8 muestra que el resultado se mantiene:

Cuadro 8: Comparación final entre finalistas tuneados de forma justa (Fase 3)

Modelo	ROC-AUC	PR-AUC	Precisión	Recall	F1
Regresión Logística (L1, $C \approx 0,0108$)	0.9668	0.9621	0.8635	0.9136	0.8878
XGBoost	0.9627	0.9589	0.8590	0.8982	0.8782




Figura 24: Curvas ROC: candidatos de línea base frente a los finalistas ya tuneados

La Regresión Logística con penalización L1 se adopta como **modelo predictivo final de la Fase 3 (Opción B)**. El hallazgo es consistente con lo encontrado en la Fase 2: la relación entre las variables institucionales y la deserción es, en esencia, bastante lineal en la escala logit, por lo que la flexibilidad adicional de un ensemble de árboles no se traduce en mejor generalización sobre cohortes futuras. Como beneficio adicional no buscado, la penalización L1 llevó a exactamente 0 los coeficientes de 15 de las 47 variables candidatas, conservando un grado de interpretabilidad que la Fase 3 no exigía pero tampoco descartaba (Figura 25).




Figura 25: Importancia de variables del modelo final (magnitud del coeficiente L1 estandarizado)

Las variables de mayor peso – `semestre_actual`, `promedio_calificacion_final`, `materias_cursadas_totales` y `std_calificacion_final` – coinciden con los factores ya identificados como los de mayor efecto en la Fase 2, seguidas de varios promedios por área de conocimiento y dummies de `id_carrera`, aprovechables aquí sin la limitación numérica que impidió incluir esta última en el Logit combinado de la Fase 2.

9.3. Optimización del umbral: un hallazgo sobre estabilidad temporal

El umbral que maximiza el F1 de Deserción en las probabilidades *out-of-fold* de entrenamiento resultó ser 0.28, no 0.5. Sin embargo, al aplicar ambos umbrales sobre las cohortes de prueba (Tabla 9), el umbral por defecto generaliza mejor:

Cuadro 9: Umbral óptimo por validación cruzada vs. umbral por defecto (evaluados en prueba)

Umbral	Precisión	Recall	F1
Por defecto (0.5)	0.8635	0.9136	0.8878
Óptimo por CV en entrenamiento (0.28)	0.9482	0.7474	0.8359

Este resultado se documenta como un hallazgo metodológico en sí mismo, no como un error a ocultar: es evidencia adicional – ahora a nivel del umbral de decisión, no solo de las variables – de que las cohortes futuras tienen una distribución distinta a las de entrenamiento. Se conserva el umbral 0.5 para el modelo final, por ser el que efectivamente generaliza mejor sobre datos nunca vistos.

9.4. Validación de la premisa dinámica: desempeño por landmark

La Tabla 10 desglosa el desempeño del modelo final en cada uno de los 3 momentos de revisión de Tutorías, confirmando la premisa central de la Fase 3: la certeza de la predicción aumenta conforme se dispone de más información dentro del semestre en curso.

Cuadro 10: Desempeño del modelo final por landmark

Landmark	ROC-AUC	Precisión	Recall	F1
1 (solo P1)	0.9590	0.8483	0.9078	0.8771
2 (P1+P2)	0.9684	0.8667	0.9168	0.8910
3 (P1+P2+P3)	0.9725	0.8757	0.9161	0.8955

9.5. Calibración de probabilidades

La Figura 26 muestra la curva de confiabilidad del modelo final. El *Brier score* obtenido fue de 0.0788, sensiblemente mejor que el ≈ 0.166 que obtendría un modelo ingenuo que solo prediga la tasa base de graduación (79%). La curva se ajusta razonablemente a la diagonal de calibración perfecta en casi todo el rango, por lo que la probabilidad de riesgo puede emplearse directamente en el programa de Tutorías, sin requerir un recalibrador adicional.




Figura 26: Curva de calibración del modelo final

9.6. Opción A vs. Opción B: ¿ayuda especializar por landmark?

La Tabla 11 compara el modelo único de la Opción B contra los 3 modelos independientes de la Opción A, evaluados sobre las mismas instantáneas de prueba.

Cuadro 11: Comparación Opción A (modelos independientes) vs. Opción B (modelo único)

Landmark	Enfoque	ROC-AUC	Precisión	Recall	F1
1	Opción B (modelo único)	0.9590	0.8483	0.9078	0.8771
1	Opción A (modelo por landmark)	0.9590	0.8435	0.9154	0.8780
2	Opción B (modelo único)	0.9684	0.8667	0.9168	0.8910
2	Opción A (modelo por landmark)	0.9683	0.8644	0.9161	0.8895
3	Opción B (modelo único)	0.9725	0.8757	0.9161	0.8955
3	Opción A (modelo por landmark)	0.9724	0.8885	0.9044	0.8964

Las diferencias entre ambos enfoques están dentro del ruido esperado (milésimas de ROC-AUC y F1) en los 3 landmarks: especializar por landmark no aporta una mejora medible sobre el modelo único. La variable `landmark_parcial`, incluida explícitamente en la Opción B, ya captura prácticamente toda la especialización que un modelo independiente por landmark podría ofrecer. Con desempeño estadísticamente empatado, se prefiere la opción más simple de desplegar y mantener: **la Opción B queda como el modelo predictivo final de la Fase 3**. Los 3 modelos de la Opción A quedan documentados como evidencia de esta comparación, no como candidatos a producción.

9.7. Cierre de la Fase 3

El modelo final – Regresión Logística con penalización L1 sobre la matriz de diseño dinámica completa (variable `landmark_parcial` incluida) – alcanza un ROC-AUC de 0.9668 sobre cohortes de ingreso completamente futuras respecto al entrenamiento, con una mejora dinámica válida landmark a landmark y probabilidades razonablemente bien calibradas. Queda validado, además, que compartir la información de los 3 landmarks en un único modelo no sacrifica desempeño frente a especializar un modelo por cada uno, simplificando su eventual despliegue operativo en el programa de Tutorías de la UTM.

10. Limitaciones metodológicas y decisiones de alcance

Por transparencia metodológica, se documentan explícitamente las siguientes decisiones de alcance adoptadas durante las Fases 1, 2 y 3, cuya resolución completa se considera fuera del alcance de este trabajo:

- **Identidad de asignaturas a través del tiempo:** como se describió en la Sección 6.4, el identificador de materia del sistema de origen no es estable entre periodos, una deuda técnica del sistema escolar ajena a los datos analizados. La coincidencia exacta por nombre normalizado adoptada subestima de forma conservadora el recursamiento en los casos – minoritarios, según la revisión manual de los nombres de asignaturas – en que una materia fue renombrada semánticamente (p. ej., de “Física 1” a “Física para la Ingeniería 1”) entre versiones del plan de estudios.
- **Mezcla de versiones del plan de estudios:** la base de datos no registra la versión del plan de estudios vigente para cada cohorte dentro de una misma carrera, por lo que estadísticos como el semestre típico de aparición de una categoría de conocimiento (Sección 4) agregan información de distintas eras curriculares de la misma carrera.
- **Arrastre por prerrequisitos:** el reglamento institucional establece que ciertas asignaturas exigen la acreditación previa de una materia prerrequisito (p. ej., Física I antes de Física II) y que la reprobación de la primera no incrementa el conteo de materias reprobadas de la segunda, sino que la marca como “no cursada”. Modelar explícitamente esta cadena de prerrequisitos requeriría un mapeo curricular materia-a-materia no disponible en la base de datos actual, y se deja como línea de trabajo futuro.
- **Excepciones no codificadas:** la posibilidad, no contemplada en el reglamento escrito, de que un Consejo de Maestros autorice un tercer recursamiento tras agotar el examen especial, se identificó como un mecanismo excepcional que afecta a un número marginal de casos y se trató como un valor atípico (*outlier*) sin tratamiento diferenciado.
- **Variables de cobertura curricular:** las variables que miden la fracción de una categoría de conocimiento ya cursada se excluyeron tanto del modelo explicativo de la Fase 2 como del predictivo de la Fase 3, por el riesgo de fuga de información descrito en la Sección 5.
- **Modelo de secuencia para la trayectoria del alumno:** la Fase 3 modela cada instantánea por landmark como una fila independiente. Un enfoque de secuencia (LSTM/GRU o Transformer) que trate la trayectoria semestre-a-semestre completa de un alumno como una serie temporal es conceptualmente distinto – podría capturar patrones de trayectoria (aceleración o desaceleración del rezago, por ejemplo) que el enfoque tabular no ve –, pero requeriría rediseñar la estructura de datos (secuencias con relleno por alumno) y la metodología de evaluación, por lo que se deja como línea de trabajo futuro.

Referencias

- Agrwal, L. & Paik, A. (2015). A survey on data mining techniques for early prediction of student drop out. *International Journal on Computer Science and Engineering*, 7(7):61–70.
- Alban, M. & Mauricio, D. (2019). Predicting university dropout through data mining: A systematic literature. *Indian Journal of Science and Technology*, 12(4):1–12.
- Bergsma, W. (2013). A bias-correction for cramér’s v and tschuprow’s t . *Journal of the Korean Statistical Society*, 42(3):323–328.
- Boswell, D. & Foucher, T. (2011). *The Art of Readable Code*. O’Reilly Media, Inc., Sebastopol, CA.
- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth International Group, Belmont, CA.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, 2nd edition.
- Cramér, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press, Princeton, NJ.
- Dijkstra, E. W. (1982). *Selected Writings on Computing: A Personal Perspective*. Springer-Verlag, New York.
- Fowler, M. (2002). *Patterns of Enterprise Application Architecture*. Addison-Wesley Longman Publishing Co., Inc., Boston, MA.
- Gopar Rodríguez, F. (2023). Características socioeconómicas de desertores escolares en una universidad pública de Oaxaca. *Ciencia Latina Revista Científica Multidisciplinar*, 7(1).
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on tabular data? *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 35:507–520.
- Gómez Morales, J. G. (2022). Factores y estrategias que influyen en la deserción en educación superior: Revisión sistemática. *RIDE Revista Iberoamericana para la Investigación y el Desarrollo Educativo*, 13(25):1–20.
- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition.
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons, Hoboken, NJ, 3rd edition.
- Kaplan, E. L. & Meier, P. (1958). Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282):457–481.

- Kehm, B. M., Larsen, M. R., & Sommersel, H. B. (2019). Student dropout from universities in europe: A review of empirical literature. *Hungarian Educational Research Journal*, 9(2):147–164.
- Kovačić, Z. J. (2010). Predicting student success by mining enrollment data. *Research in Higher Education Journal*, 8:1–15.
- Kuhn, M. & Johnson, K. (2013). *Applied Predictive Modeling*. Springer, New York.
- Manrique, R., Nunes, B., Marino, O., Casanova, M., & Nurmikko-Fuller, T. (2019). Early prediction of student dropout in university courses using machine learning. *Proceedings of the 34th ACM/SIGAPP Symposium on Applied Computing*, pages 2456–2459.
- Martin, R. C. (2017). *Clean Architecture: A Craftsman's Guide to Software Structure and Design*. Prentice Hall, Boston, MA.
- Miño de Gauto, M. E. (2021). Factores condicionantes de la deserción universitaria. *Ciencia Latina Revista Científica Multidisciplinar*, 5(4):5316–5328.
- Munson, T. (2011). *Data Preprocessing in Predictive Data Mining*. John Wiley & Sons, New Jersey.
- National Institute of Standards and Technology (NIST) (2015). Secure hash standard (shs). FIPS PUB 180-4, U.S. Department of Commerce.
- O'Brien, R. M. (2007). A caution regarding rules of thumb for variance inflation factors. *Quality & Quantity*, 41(5):673–690.
- Parnas, D. L. (1972). On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, 15(12):1053–1058.
- Peng, C.-Y. J., Lee, K. L., & Ingersoll, G. M. (2002). An introduction to logistic regression analysis and reporting. *The Journal of Educational Research*, 96(1):3–14.
- Prekaj, B., Velardi, P., Stilo, G., Distant, D., & Faralli, S. (2020). A survey of machine learning approaches for student dropout prediction in online courses. *ACM Computing Surveys (CSUR)*, 53(3):1–34.
- Pérez-Jaimes, A. K., Estrada-Reyes, C. U., & Hurtado-Velmar, K. P. (2022). Factores causales de la deserción escolar en alumnos de nivel superior. *Revista de Investigación Latinoamericana en Competitividad Organizacional*, 7(25):1–10.
- Quinlan, J. R. (1986). Induction of decision trees. *Machine learning*, 1(1):81–106.
- Rastrollo-Guerrero, J. L., Gómez-Pulido, J. A., & Durán-Domínguez, A. (2020). Analyzing and predicting students' performance by means of machine learning: A review. *Applied Sciences*, 10(3):1042.

- Rose-Parra, C., Cervera-Manjarrez, N., Oquendo-González, E. J., & Velásquez-Pérez, Y. (2023). Factores que influyen en la deserción estudiantil en la educación terciaria de Colombia. *CIENCIAMATRIA*, 9(17):45–56.
- Shwartz-Ziv, R. & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, 81:84–90.
- Szumilas, M. (2010). Explaining odds ratios. *Journal of the Canadian Academy of Child and Adolescent Psychiatry*, 19(3):227–229.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1):267–288.
- Tinto, V. (1975). Dropout from higher education: A theoretical synthesis of recent research. *Review of educational research*, 45(1):89–125.
- Universidad Tecnológica de la Mixteca (2024). Reglamento de alumnos de licenciatura 2024.
- van Houwelingen, H. C. (2007). Dynamic prediction by landmarking in event history analysis. *Scandinavian Journal of Statistics*, 34(1):70–85.
- Vera, C. M., Morales, C. R., & Soto, S. V. (2012). Factores asociados a la deserción universitaria. *Revista de Educación Superior*, 41(1):25–48.
- Wiggins, A. (2011). *The Twelve-Factor App*. Accedido en mayo de 2026.
- Zheng, A. & Casari, A. (2018). *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. O'Reilly Media, Inc., Sebastopol, CA.