

Predicción de la deserción escolar con base en factores institucionales de los estudiantes de la UTM

Méndez Luis Yakin Senen

Universidad Tecnológica de la Mixteca
Instituto de Computación

Reporte de Avance Metodológico y EDA

Planteamiento del Problema

Contexto Institucional

- La deserción temprana afecta la eficiencia terminal de la UTM.
- Existe una base transaccional masiva (calificaciones, asistencias), pero actualmente se usa solo para consulta administrativa.
- El sistema de tutorías opera de manera reactiva, no proactiva.

El Problema Central

- Carencia de un modelo analítico que cuantifique qué factores institucionales impulsan la deserción.
- Falta de un sistema de alerta temprana basado en datos para focalizar esfuerzos de retención.

Objetivo del Proyecto

Modelar la relación entre factores institucionales (restricción estricta a rendimiento académico y asistencia) y la deserción estudiantil, para desarrollar un sistema de alerta temprana predictivo.

Fases de la Metodología:

- 1 **Fase Descriptiva:** Extracción, saneamiento y EDA (Fase actual completada).
- 2 **Fase Explicativa:** Identificar determinantes clave del abandono.
- 3 **Fase Predictiva:** Entrenamiento del modelo de Machine Learning (Próximo paso).

Arquitectura de Procesamiento de Datos

Se implementó una arquitectura modular bajo el principio de *Separación de Intereses (SoC)* para garantizar reproducibilidad técnica.

Módulo	Responsabilidad
<code>db_connector.py</code>	Abstracción ORM segura aislando credenciales.
<code>data_cleaner.py</code>	Sanitización y manejo de anomalías transaccionales.
<code>feature_engineer.py</code>	Anonimización y construcción de representaciones longitudinales.
<code>eda_visualizer.py</code>	Renderizado encapsulado de pruebas estadísticas.

Población base extraída: 133,882 registros de calificaciones.

Perfilado de Datos Crudos y Saneamiento

El *Data Profiling* automatizado reveló que los datos transaccionales contenían ruido administrativo incompatible con el modelado matemático:

- **Banderas del Sistema:** Calificaciones negativas (-10.0 o -8.0) usadas por el sistema NES para indicar evaluaciones no capturadas o bajas temporales.
- **Inflación de ceros lógicos:** Altas concentraciones de 0.0 que representaban abandono de aula antes de la evaluación.


Solución: El módulo `data_cleaner` reemplazó las banderas negativas por estructuras nulas (NaN) para evitar sesgar las varianzas.

Preparación de los datos para el aprendizaje automático:

- **Anonimización y Trazabilidad:** Creación de `alumno_carrera_hash` (SHA-256). Detectó matemáticamente 322 eventos de movilidad interna (cambio de carrera).
- **Categorización Semántica:** Mapeo de más de 6,600 materias a “Áreas de Conocimiento” usando Expresiones Regulares para evitar matrices dispersas.
- **Instantáneas (Snapshots):** Estructuración acumulativa iterativa por semestre para evitar “Fuga de Información” (*Data Leakage*).
- **Etiquetado (Target):** Inferencia del estado final de graduación/retención (1) vs. deserción (0) basado en el historial longitudinal.

Estudio de Independencia (χ^2)


- Se corroboró el peso institucional de la regla del 80 % de asistencias.
- Se evidencia un claro “efecto escalera”: la deserción domina en categorías de riesgo ($< 80\%$).
- Estudiantes con asistencia excelente ($\geq 95\%$) tienen éxito casi total.



Resultados del EDA: El Sesgo de Supervivencia

Fuerza Predictiva


- La correlación Punto-Biserial arrojó un resultado anómalo: Administración y Humanidades parecían “proteger” más que Matemáticas.
- **Diagnóstico:** Sesgo de supervivencia. Los desertores abandonan en los ciclos básicos. Solo los que superan el filtro logran cursar materias de grados superiores.



Resultados del EDA: Umbrales y Rezago

El filtro real: Ciencias Básicas

- El análisis de densidad en Matemáticas muestra un claro umbral de supervivencia.
- Promedios por debajo de 6.5 disparan drásticamente el riesgo de pertenecer a la población de desertores.
- La tolerancia al rezago (materias reprobadas acumuladas) es casi nula para el grupo de graduados.



Conclusión Parcial y Siguietes Pasos

Logros a la fecha:

- Se cuenta con un conjunto de datos saneado, balanceado e ingenierizado que refleja fielmente las reglas institucionales de la UTM.
- El EDA valida estadísticamente que factores predictivos como inestabilidad de calificaciones, ausentismo y desempeño en ciencias básicas son excelentes separadores de clases.

Siguietes Pasos (Fase Predictiva):

- Entrenamiento de algoritmos de clasificación supervisada (Regresión Logística, Árboles de Decisión, XGBoost).
- Evaluación de métricas de precisión (Precision, Recall, F1-Score).
- Generación de la salida del semáforo de riesgo predictivo.

¡Gracias!

Preguntas y retroalimentación.