

Predicción de la deserción escolar con base en factores institucionales de los estudiantes de la UTM

Méndez Luis Yakin Senen

Universidad Tecnológica de la Mixteca
Instituto de Computación

Reporte de Avance: Metodología, EDA y Análisis Explicativo

Planteamiento del problema

Contexto institucional

- La deserción temprana reduce la eficiencia terminal en la educación superior y en la UTM.
- Se cuenta con una base de datos transaccional masiva (calificaciones, asistencias), actualmente utilizada exclusivamente para fines administrativos.
- Los programas institucionales (como tutorías) operan bajo un esquema reactivo y no proactivo.

Problema central

- Carencia de un modelo analítico validado que explique y prediga el abandono escolar utilizando únicamente factores institucionales internos.

Objetivos y estado actual del proyecto

Objetivo general: Modelar la relación entre factores institucionales (rendimiento y asistencia) y la deserción para desarrollar un sistema de alerta temprana.

Fases metodológicas:


- 1 **Fase descriptiva:** Extracción, perfilado, saneamiento y EDA.
- 2 **Fase explicativa:** Aislamiento de colinealidad (VIF), modelado Logit (Odds Ratios) y Árboles de Decisión .
- 3 **Fase predictiva:** Diseño y validación de modelos de Machine Learning para el semáforo de riesgo.

- **Arquitectura modular (SoC y SRP):** Paquete src/ estructurado en conectores ORM, limpiadores de datos, generadores de características y visualizadores analíticos.
- **Saneamiento de registros crudos:**
 - Identificación de valores negativos (-10.0, -8.0) como banderas de control administrativo del sistema NES.
 - Conversión sistemática a estructuras nulas estándar (NaN) para proteger el cálculo de varianzas.
- **Ingeniería de características:**
 - Anonimización criptográfica SHA-256 (`alumno_carrera_hash`), detectando 322 eventos de movilidad interna.
 - Mapeo semántico de 6,666 materias mediante expresiones regulares en áreas de conocimiento.

Hallazgos del análisis exploratorio (EDA)

Evidencia estadística inicial:


- **Asistencia** ($\chi^2 = 2755,74$): Se comprueba el peso crítico de la regla del 80 %. Se observa un claro “efecto escalera” en las tasas de retención.
- **Sesgo de supervivencia**: Las correlaciones bivariadas iniciales en materias avanzadas respondían al abandono temprano en ciclos básicos.
- **Umbrales en ciencias básicas**: Promedios por debajo de 6.5 en matemáticas elevan de forma exponencial el riesgo de deserción.



Fase explicativa: Diagnóstico de multicolinealidad (VIF)

Depuración matemática de variables:

- Se calculó el Factor de Inflación de la Varianza (VIF) con un umbral conservador de $\leq 5,0$.
- Se eliminaron variables con colinealidad perfecta (como materias cursadas y promedio global acumulado).
- La matriz final quedó depurada con **15 características ortogonales** independientes y estables.



Fase explicativa: Modelo logit (Odds Ratios)


Se ajustó una regresión logística con un sobresaliente **Pseudo R^2 de 0.2949** (ajuste excelente en estudios educativos).

Cuantificación del impacto (razón de momios):

- **Cursos de verano (OR = 2.003):** Estudiantes que regularizan en verano duplican sus probabilidades de graduarse (mecanismo de resiliencia).
- **Inestabilidad académica (OR = 0.544):** Cada punto de incremento en la desviación estándar de las calificaciones reduce las probabilidades de éxito en un **45.6 %**.
- **Constancia en asistencia (OR = 1.049):** Cada 1 % de mejora sostenida en la asistencia incrementa un **5 %** las probabilidades de éxito.

Árbol de decisión interpretables ($max_depth = 3$):

- Traduce las matemáticas a reglas operativas para el sistema de tutorías de la UTM.
- El primer nodo de quiebre evalúa el desempeño en áreas formativas base (ej. Administración y Gestión con umbral de 5.97).
- Filtra de manera secuencial a los alumnos de alto riesgo cruzando el rendimiento con el *promedio_asistencia_final* ($\approx 90,5\%$).



Conclusiones parciales y siguientes pasos

Logros alcanzados:

- Saneamiento y estructuración temporal rigurosa sin fugas de información.
- Modelado explicativo sólido que identifica el ausentismo y la inestabilidad de calificaciones como principales impulsores de riesgo.

Siguientes pasos:

- Implementación de clasificadores supervisados avanzados (Random Forest, XGBoost) sobre la matriz depurada por VIF.
- Calibración de métricas de desempeño (Precision, Recall y Curva ROC-AUC) enfocadas en la minimización de falsos positivos para las alertas tempranas.

¡Gracias!

Apertura a preguntas y retroalimentación.